# SeguWatts

Componente Dados: pipeline de Big Data para uso consciente de energia residencial


| Nome completo | RM |
|---|---|
| Davi Passanha de Sousa Guerra | RM551605 |
| Cauã Gonçalves de Jesus | RM97648 |
| Luan Silveira Macea | RM98290 |
| Rui Amorim Siqueira | RM98436 |
| Luigi Ferrara Sinno | RM98047 |



Global Solution 2026.2 · FIAP · Engenharia de Software, 4º ano
Big Data Architecture & Data Integration
Repositório: https://github.com/luanmacea/seguwatts-bigdata

## 01. Integrantes

| Nome completo | RM |
|---|---|
| Davi Passanha de Sousa Guerra | RM551605 |
| Cauã Gonçalves de Jesus | RM97648 |
| Luan Silveira Macea | RM98290 |
| Rui Amorim Siqueira | RM98436 |
| Luigi Ferrara Sinno | RM98047 |

## 02. O produto e as perguntas que o MVP responde

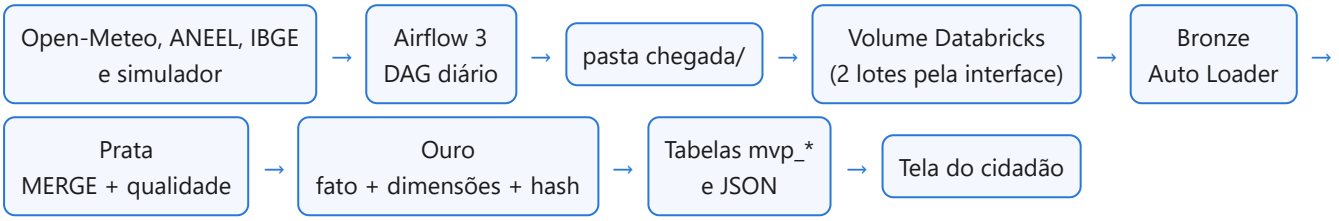
> O SeguWatts mostra ao morador quando e onde a casa gasta energia, quanto isso custa e qual aparelho pode estar com defeito, antes que o problema apareça na conta.

**Cidadão:** famílias de renda baixa e média no estado de São Paulo, para quem a conta de luz pesa no orçamento. **ODS:** 10 (redução das desigualdades), 11 (cidades sustentáveis) e 13 (ação climática).

| # | Pergunta do cidadão | Consulta |
|---|---|---|
| 1 | Em que dia da semana e horário minha casa gasta mais? | q1 |
| 2 | Como meu gasto muda de mês para mês, com o calor e a bandeira tarifária? | q2 |
| 3 | Qual aparelho pesa mais na minha conta? | q3 |
| 4 | Algum aparelho está gastando mais do que deveria? | q4 |
| 5 | Quanto eu economizo se resolver esses problemas? (impacto) | q5 |

**Como a casa é medida:** um sensor geral no quadro de energia e sensores de tomada em até três aparelhos críticos (geladeira, freezer e ar-condicionado), todos com leitura por hora, mais a conta de luz e o cadastro de aparelhos. O consumo dos demais aparelhos é o sensor geral menos as tomadas, e cada aparelho sem sensor recebe uma parte da conta proporcional a potência × horas de uso declaradas.

## 03. Diagrama do fluxo de dados




O Databricks Free Edition não se conecta ao Airflow. Por isso os arquivos de `chegada/` sobem ao Volume pela interface, em lotes. Como o navegador limita o tamanho de cada envio, cada lote foi compactado (`scripts/compactar_lotes.py`) e o notebook `00b_extrair_lote` recria as pastas dentro do Volume.

## 04. Fontes de dados

| Fonte | Origem | Formato | Frequência | Tipo |
|---|---|---|---|---|
| clima | Open-Meteo Archive API (6 municípios de SP) | JSON | Diária | Externa real |
| tarifas | ANEEL Dados Abertos: tarifas B1 residenciais | JSON | Diária | Externa real |
| bandeiras | ANEEL Dados Abertos: acionamento de bandeiras | JSON | Diária | Externa real |
| municipios | IBGE API de Localidades | JSON | Diária | Externa real |
| sensores | Simulador documentado (leituras horárias) | JSON | Diária | Simulada |
| contas | Simulador documentado (contas de luz) | JSON | Diária | Simulada |
| cadastro | Simulador documentado (moradores e aparelhos) | JSON aninhado | Diária | Simulada |

**Por que há dados simulados:** não existe base aberta de consumo por residência, e dados pessoais reais não podem ser publicados. O simulador (`dags/seguwatts/simulador.py`) é reproduzível pela semente, faz a geladeira e o ar-condicionado reagirem à temperatura real do Open-Meteo, usa identidades claramente fictícias e injeta sujeira proposital e defeitos registrados num gabarito, que permitem medir se a detecção funciona.

# 05. Requisitos 01 a 09

## Requisito 01: Duas ou mais fontes, ao menos uma externa

Quatro fontes externas reais (Open-Meteo, ANEEL tarifas, ANEEL bandeiras e IBGE) e três simuladas, todas ligadas ao problema: consumo, custo da energia e clima. Cada fonte tem uma tarefa própria no DAG.

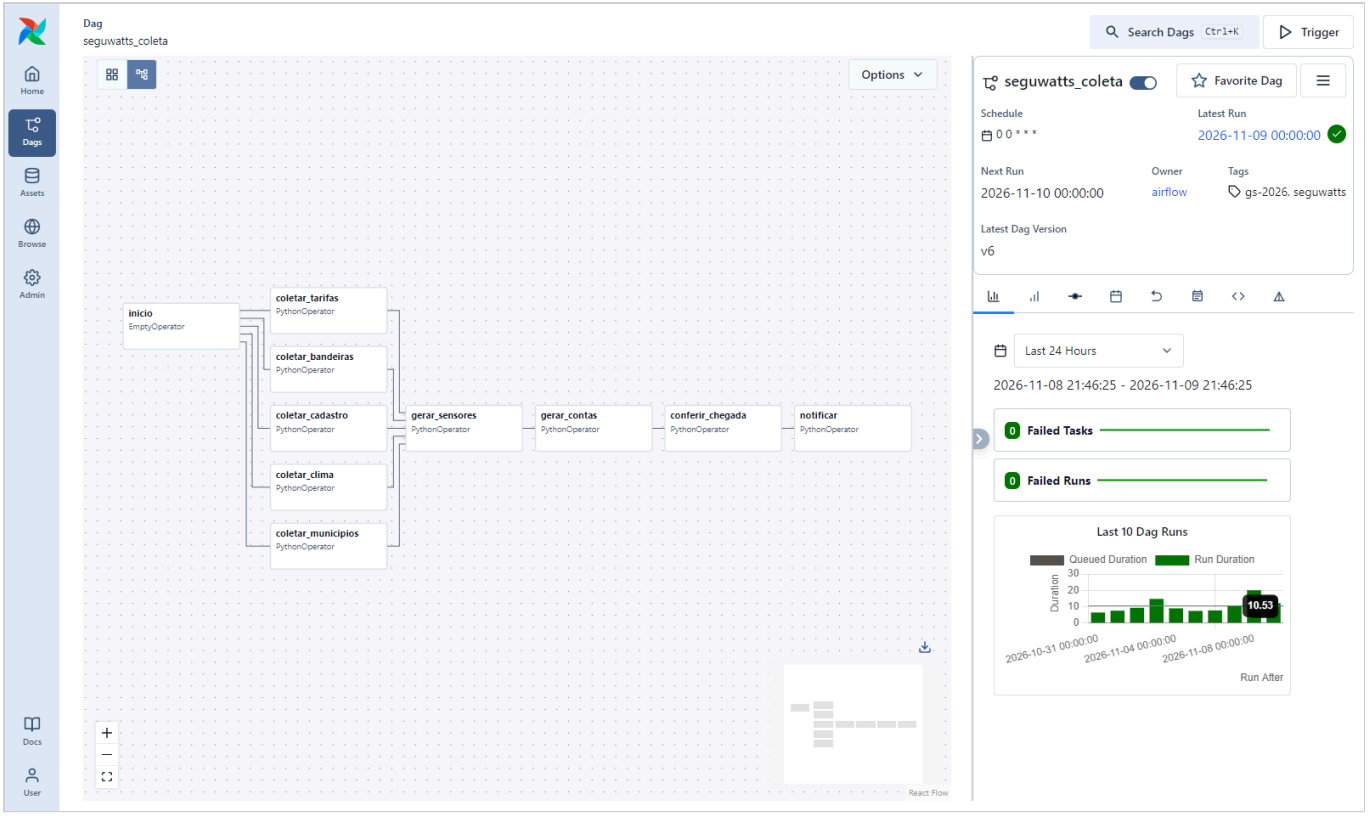



**Figura 1.** DAG `seguwatts_coleta` no Airflow 3: uma tarefa de coleta por fonte.

## Requisito 02: DAG agendado gravando na pasta chegada/

O DAG roda `@daily` com `catchup`, coleta o dia anterior e grava um arquivo por fonte com a data no nome, por exemplo `chegada/clima/clima_2026-11-08.json`. O histórico de 01/05 a 24/10 foi gerado pelas mesmas funções (`scripts/carga_historica.py`); o DAG executou de 25/10 a 08/11, com 15 execuções concluídas.

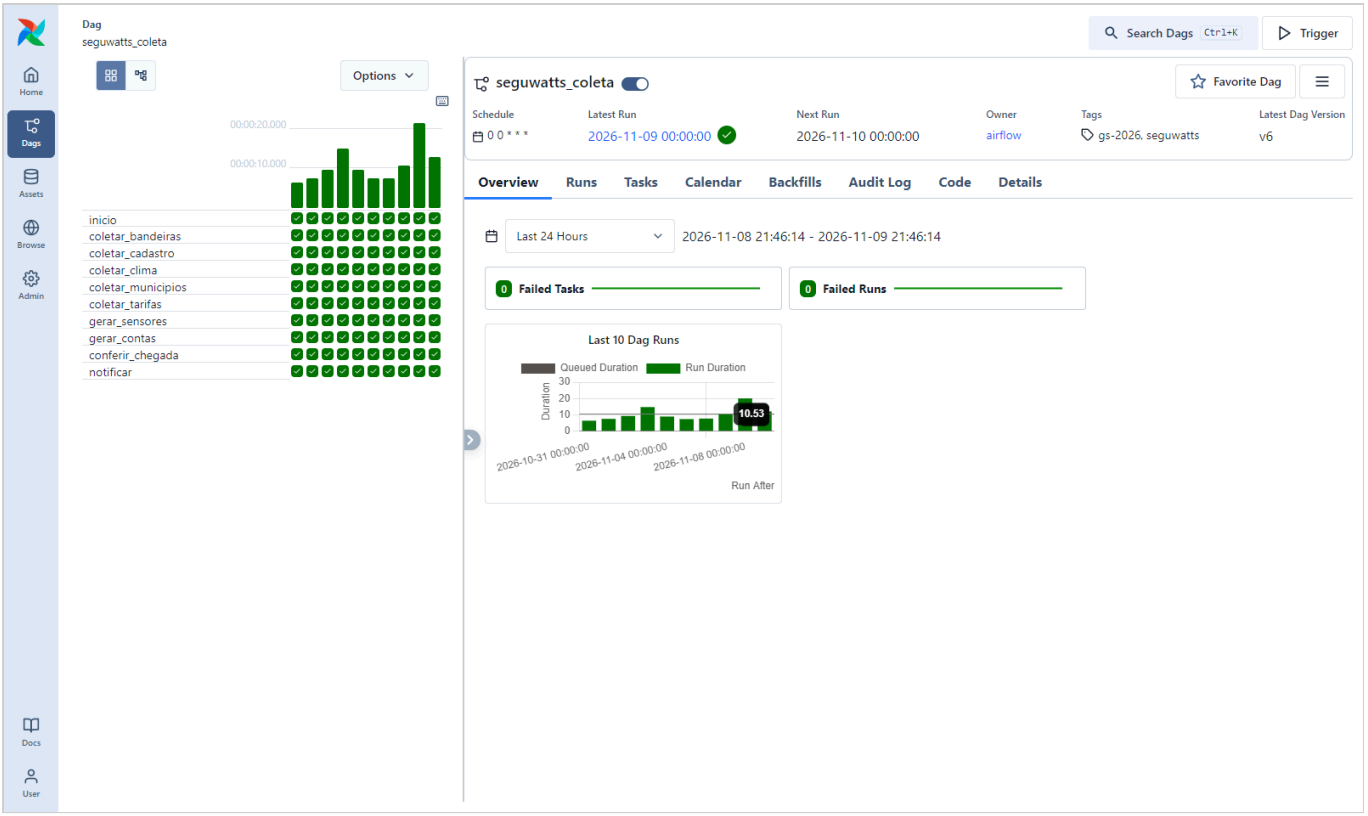



**Figura 2.** Visão Grid: execuções diárias concluídas com sucesso em todas as tarefas.

## Requisito 03: Paralelismo, verificação dos arquivos e chaves fora do código

As cinco coletas rodam em paralelo depois de `inicio` (Figura 1). `conferir_chegada` falha se faltar algum arquivo do dia ou se uma fonte obrigatória vier vazia, e `notificar` roda sempre (`all_done`), enviando o resultado ao webhook configurado. As fontes usadas não exigem chave de API; mesmo assim, toda configuração sensível fica em Airflow Variables, nunca no código:

```
def _pasta_chegada() -> str:
    return Variable.get("seguwatts_chegada", default="/opt/airflow/chegada")

def _enviar_aviso(texto: str):
    url = Variable.get("seguwatts_webhook_url", default="")
```

## Requisito 04: Dois ou mais lotes enviados ao Volume

Lote 1: dias de 01/05 a 31/10 (585 arquivos, em 2 partes compactadas). Lote 2: dias de 01/11 a 08/11 (56 arquivos). Cada lote foi enviado pela interface e extraído no Volume em momentos diferentes.

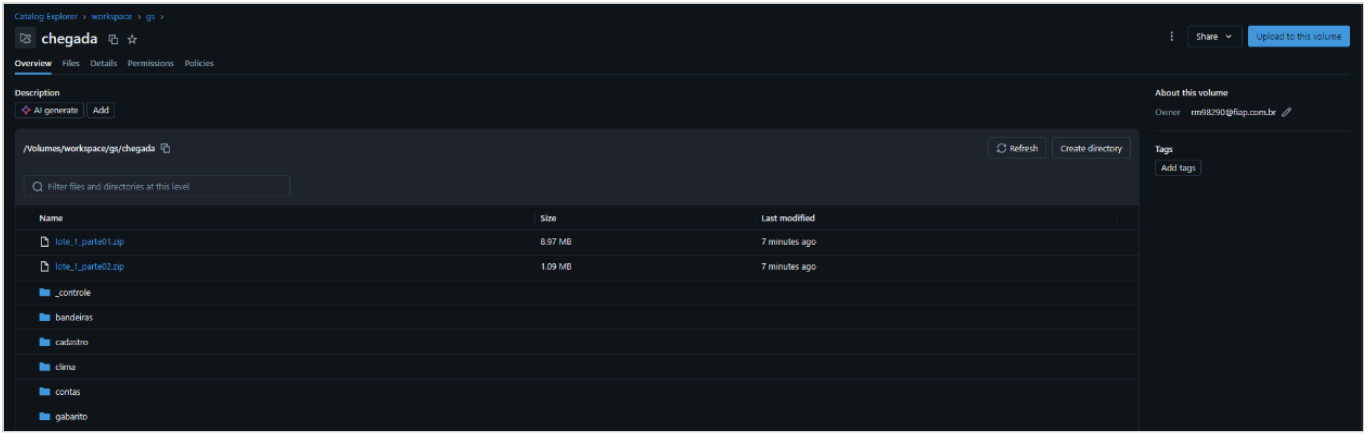



**Figura 3.** Volume `workspace.gs.chegada` com o lote 1 enviado e as pastas por fonte já extraídas.



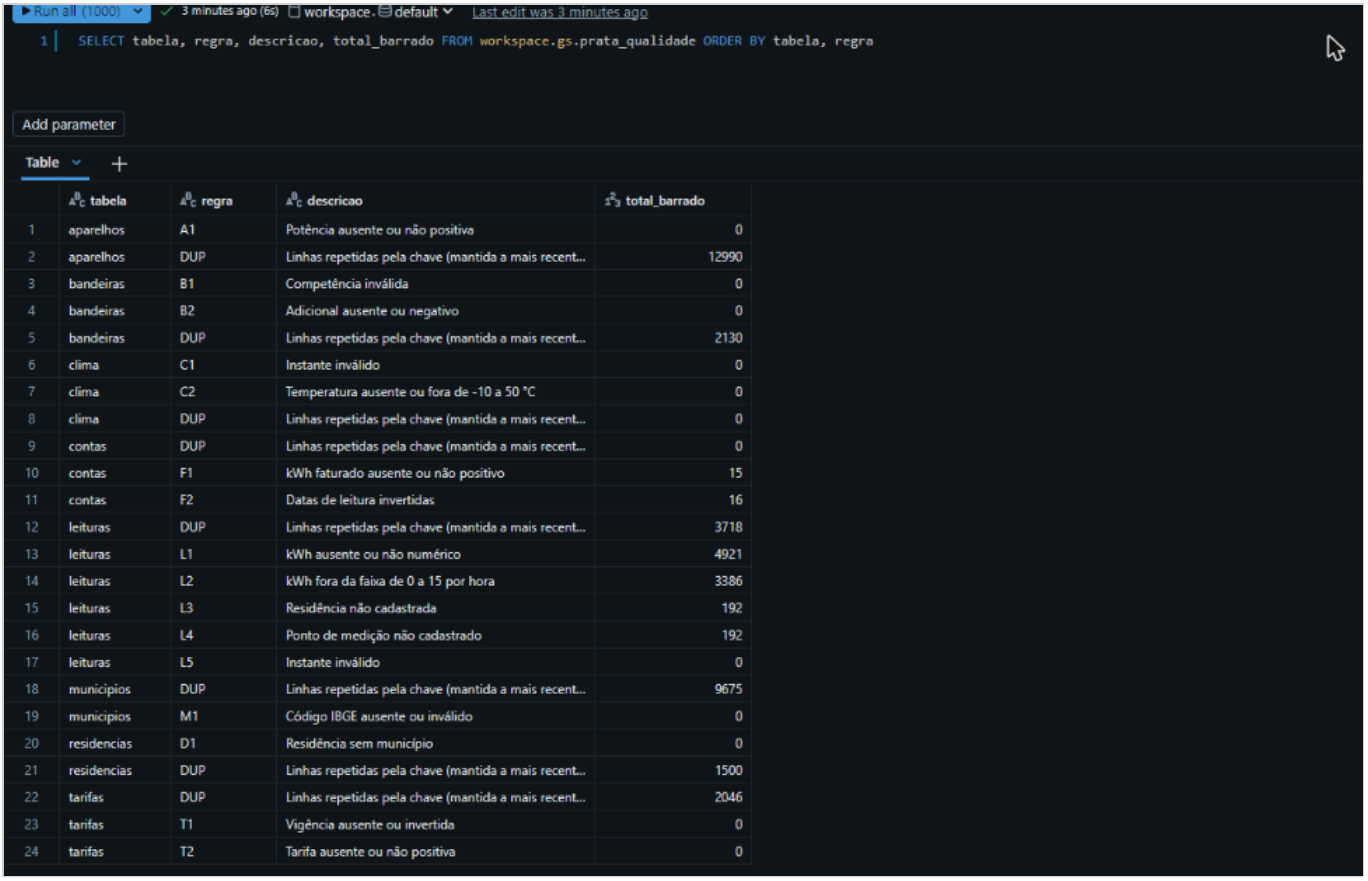

**Figura 4.** Extração do lote 2: 8 arquivos novos por fonte, de 01/11 a 08/11.

### Requisito 05: Bronze incremental e sem duplicação

Auto Loader (`cloudFiles`, `availableNow`) com checkpoint por fonte: só arquivos novos entram. As contagens antes e depois do 2º lote e da reexecução estão na seção 07.

### Requisito 06: Prata: tipos, nulos e inválidos tratados, MERGE pela chave e regras de qualidade

Cada tabela recebe tipos corretos (`try_cast`, vírgula decimal convertida), remove duplicatas pela chave e faz `MERGE`. Dezesseis regras com contagem: as linhas barradas vão para `prata_rejeitos` e os totais para `prata_qualidade`. Em `prata_leituras`, por exemplo, foram barradas 4.921 leituras sem kWh válido, 3.386 fora da faixa de 0 a 15 kWh/h, 192 de residência inexistente e 192 de ponto de medição inexistente.

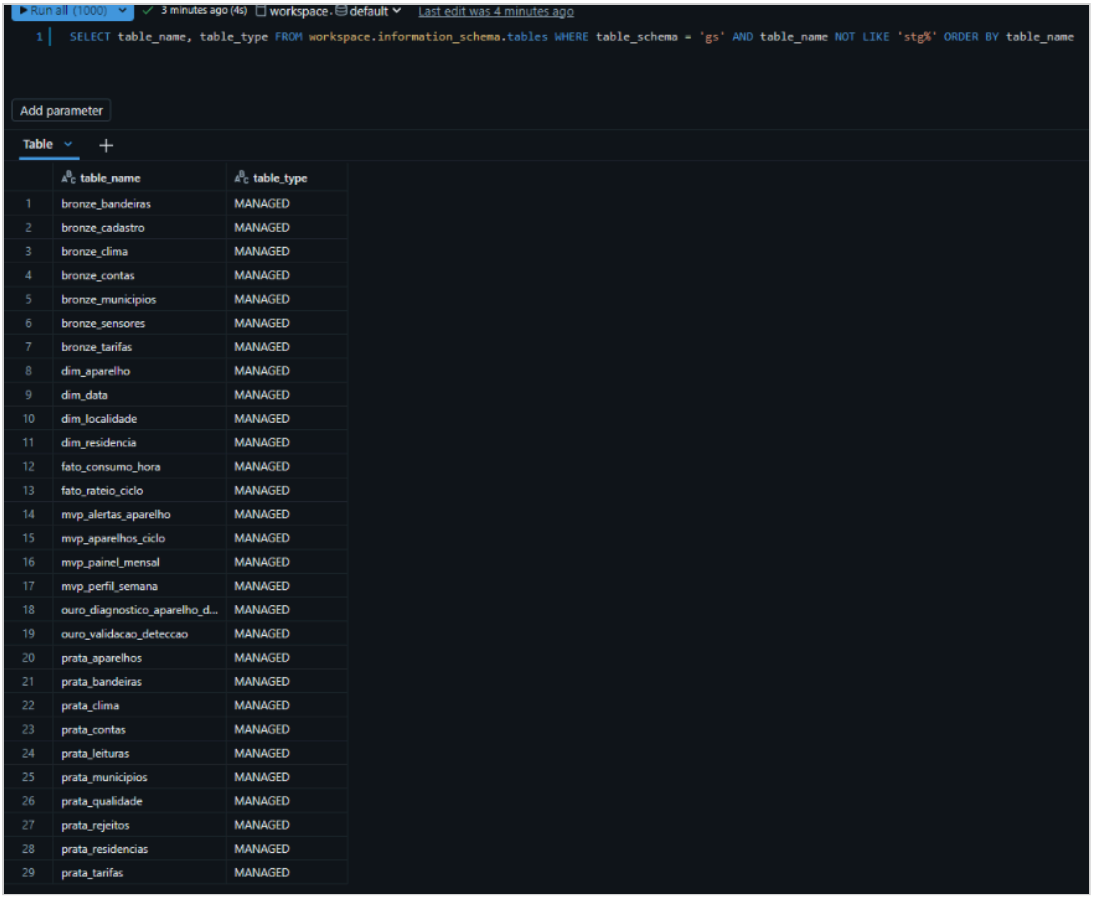



| | tabela | regra | descricao | total_barrado |
|---|---|---|---|---|
| 1 | aparelhos | A1 | Potência ausente ou não positiva | 0 |
| 2 | aparelhos | DUP | Linhas repetidas pela chave (mantida a mais recent... | 12990 |
| 3 | bandeiras | B1 | Competência inválida | 0 |
| 4 | bandeiras | B2 | Adicional ausente ou negativo | 0 |
| 5 | bandeiras | DUP | Linhas repetidas pela chave (mantida a mais recent... | 2130 |
| 6 | clima | C1 | Instante inválido | 0 |
| 7 | clima | C2 | Temperatura ausente ou fora de -10 a 50 °C | 0 |
| 8 | clima | DUP | Linhas repetidas pela chave (mantida a mais recent... | 0 |
| 9 | contas | DUP | Linhas repetidas pela chave (mantida a mais recent... | 0 |
| 10 | contas | F1 | kWh faturado ausente ou não positivo | 15 |
| 11 | contas | F2 | Datas de leitura invertidas | 16 |
| 12 | leituras | DUP | Linhas repetidas pela chave (mantida a mais recent... | 3718 |
| 13 | leituras | L1 | kWh ausente ou não numérico | 4921 |
| 14 | leituras | L2 | kWh fora da faixa de 0 a 15 por hora | 3386 |
| 15 | leituras | L3 | Residência não cadastrada | 192 |
| 16 | leituras | L4 | Ponto de medição não cadastrado | 192 |
| 17 | leituras | L5 | Instante inválido | 0 |
| 18 | municipios | DUP | Linhas repetidas pela chave (mantida a mais recent... | 9675 |
| 19 | municipios | M1 | Código IBGE ausente ou inválido | 0 |
| 20 | residencias | D1 | Residência sem município | 0 |
| 21 | residencias | DUP | Linhas repetidas pela chave (mantida a mais recent... | 1500 |
| 22 | tarifas | DUP | Linhas repetidas pela chave (mantida a mais recent... | 2046 |
| 23 | tarifas | T1 | Vigência ausente ou invertida | 0 |
| 24 | tarifas | T2 | Tarifa ausente ou não positiva | 0 |

**Figura 5.** Tabela `prata_qualidade`: total barrado por regra e linhas repetidas removidas.

### Requisito 07: Ouro dimensional e 5 consultas SQL

Fato `fato_consumo_hora` (residência × aparelho × hora, 1,2 milhão de linhas) e dimensões `dim_data`, `dim_localidade`, `dim_residencia` e `dim_aparelho`, além do fato `fato_rateio_ciclo`. O fato guarda as tomadas e as demais cargas, nunca o sensor geral junto, para não somar nada em dobro. As consultas estão na seção 08.



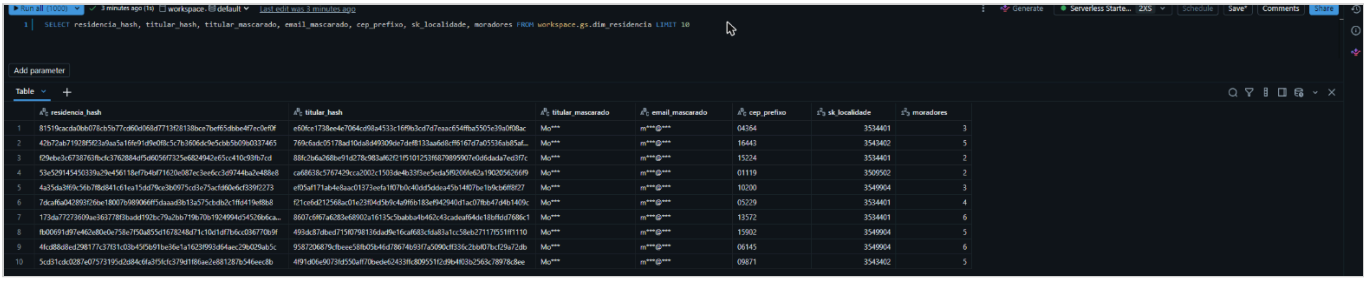
```
SELECT table_name, table_type FROM workspace.information_schema.tables WHERE table_schema = 'gs' AND table_name NOT LIKE 'stg%' ORDER BY table_name
```

| | table_name | table_type |
|---|---|---|
| 1 | bronze_bandeiras | MANAGED |
| 2 | bronze_cadastro | MANAGED |
| 3 | bronze_clima | MANAGED |
| 4 | bronze_contas | MANAGED |
| 5 | bronze_municipios | MANAGED |
| 6 | bronze_sensores | MANAGED |
| 7 | bronze_tarifas | MANAGED |
| 8 | dim_aparelho | MANAGED |
| 9 | dim_data | MANAGED |
| 10 | dim_localidade | MANAGED |
| 11 | dim_residencia | MANAGED |
| 12 | fato_consumo_hora | MANAGED |
| 13 | fato_rateio_ciclo | MANAGED |
| 14 | mvp_alertas_aparelho | MANAGED |
| 15 | mvp_aparelhos_ciclo | MANAGED |
| 16 | mvp_painel_mensal | MANAGED |
| 17 | mvp_perfil_semana | MANAGED |
| 18 | ouro_diagnostico_aparelho_d... | MANAGED |
| 19 | ouro_validacao_deteccao | MANAGED |
| 20 | prata_aparelhos | MANAGED |
| 21 | prata_bandeiras | MANAGED |
| 22 | prata_clima | MANAGED |
| 23 | prata_contas | MANAGED |
| 24 | prata_leituras | MANAGED |
| 25 | prata_municipios | MANAGED |
| 26 | prata_qualidade | MANAGED |
| 27 | prata_rejeitos | MANAGED |
| 28 | prata_residencias | MANAGED |
| 29 | prata_tarifas | MANAGED |

**Figura 6.** Tabelas do schema `workspace.gs`: Bronze, Prata, dimensões, fatos e tabelas do MVP.

## Requisito 08: LGPD na Ouro e uso dos dados pelo MVP

Na Ouro não há nome, CPF, e-mail, telefone nem o identificador original. Titular e residência viram SHA-256 com sal; o sal fica no secret, no widget ou num arquivo gerado no Volume, nunca no repositório. O MVP consome apenas as tabelas `mvp_*`, exportadas em JSON (contrato em `docs/contrato_mvp.md`).



```
SELECT residencia_hash, titular_hash, titular_mascarado, email_mascarado, cep_prefixo, sk_localidade, moradores FROM workspace.gs.dim_residencia LIMIT 10
```

| | residencia_hash | titular_hash | titular_mascarado | email_mascarado | cep_prefixo | sk_localidade | moradores |
|---|---|---|---|---|---|---|---|
| 1 | 81519cacda0bb078cb5b77cd60d068d7713f08138bce7bef65dbbe4f7ec0ef0f | e606ce1738ee4e7064cd98a4533c16f8b3cd7d7eaac654ffba5505e39a0f0bac | Mo*** | m***@*** | 04364 | 3534401 | 3 |
| 2 | 42b72ab71928f5f23a9aa5a16fe91d9e08c5c7b3606dc9e5cbb5b09b0337465 | 769c6adc05178ad10da8d49309de7dfeff8133aa6e8cff6167d7a01536a8d5af... | Mo*** | m***@*** | 16443 | 3543402 | 5 |
| 3 | f29ebe3c67383763fbcfc3762884df5d60569f7325e6824942e65cc410c93fb7cd | 886c2b6a268be91d278c983a662f21f5101253f68789895907e0d6dada7ed3f7c | Mo*** | m***@*** | 15224 | 3534401 | 2 |
| 4 | 53e529145456339a29e45618ef7b4bf71620e087ec3ee6cc3d9744ba2e488e8 | ca68638c5767429cca2002c1503de4b33f3ee5eda5ff0266b62a1902056266f9 | Mo*** | m***@*** | 01119 | 3509502 | 2 |
| 5 | 4a35da3f69c56b78bd841c61ea15dd78cc3b0975cd3e75acfd60e6ef339f2273 | ef05af171ab4e8aac01373eefa107bb0c40dd5ddec45b14407be1b9cbb6f6f827 | Mo*** | m***@*** | 10200 | 3549904 | 3 |
| 6 | 7dcaf6a042893f6be18007b989066ff5daaad3b13a575cbdb2c1f6d419ef8b8 | f21cef62125568c01e23f04d5bf6c4a0f6b182ef942940d1ac078bb47d4b1409c | Mo*** | m***@*** | 05229 | 3534401 | 4 |
| 7 | 173da772736b9ae163778f3badd1928bc79a2bb719b70b192499d54526b6ca... | 8607c6f67a6283e68902a161335c5babba4b462c43cadeaf64de18bf8dd768bc1 | Mo*** | m***@*** | 13572 | 3534401 | 6 |
| 8 | fb00691d97e462e80e0e758e7550a855d1678248d71c10d1df7b6cd3677f0b9f | 493dc87dbed715f0798136dad9e16caf683c1da83a1cc58eb27117551ff1110 | Mo*** | m***@*** | 15902 | 3549904 | 5 |
| 9 | 4fcd88d8ed298177c37f31c03b4595b91be36e1a1623f993d64aec29b029ab5c | 9587206879cfbeee58fb05b46d78674b937a5090cff336c2bb0f07bcf29a72db | Mo*** | m***@*** | 06145 | 3549904 | 6 |
| 10 | 5cd31cdc0287e07573195d2d84c6fa3f5fcfc379df186ae2e881287b546eec8b | 4f91d06e90734d550aff70bede62433ffc8095512d9b4f03b2563c78978c8ee | Mo*** | m***@*** | 09871 | 3543402 | 5 |

**Figura 7.** `dim_residencia`: identificadores em hash, titular e e-mail mascarados, CEP com 5 dígitos.



```
SELECT left(residencia_hash, 12) AS residencia, rotulo, status, excesso_pct, desde, rs_excesso_mes, mensagem FROM workspace.gs.mvp_alertas_aparelho WHERE status IN ('atencao', 'critico') ORDER BY excesso_pct DESC LIMIT 12
```

| | residencia | rotulo | status | excesso_pct | desde | rs_excesso_mes | mensagem |
|---|---|---|---|---|---|---|---|
| 1 | 033882f719aa | Demais aparelh... | critico | 73 | 2026-09-14 | 76.41 | O consumo dos aparelhos sem sensor subiu cerca de 73%. Veja se algo ficou ligado sem necessidade. |
| 2 | 7c1666133f60 | Demais aparelh... | critico | 69 | 2026-07-24 | 59.08 | O consumo dos aparelhos sem sensor subiu cerca de 69%. Veja se algo ficou ligado sem necessidade. |
| 3 | 0feaff855f53 | Demais aparelh... | critico | 61 | 2026-09-08 | 76.22 | O consumo dos aparelhos sem sensor subiu cerca de 61%. Veja se algo ficou ligado sem necessidade. |
| 4 | 1e9b88842eac | Geladeira | critico | 45 | 2026-09-17 | 15.95 | Geladeira: consumo cerca de 45% acima do próprio normal. Vale pedir uma verificação. |
| 5 | f54870ba4f76 | Geladeira | critico | 45 | 2026-08-12 | 14.38 | Geladeira: consumo cerca de 45% acima do próprio normal. Vale pedir uma verificação. |
| 6 | fedc42bfe580 | Geladeira | critico | 44 | 2026-08-25 | 14.31 | Geladeira: consumo cerca de 44% acima do próprio normal. Vale pedir uma verificação. |
| 7 | 7ffe6f5b2224 | Geladeira | critico | 42 | 2026-09-06 | 13.64 | Geladeira: consumo cerca de 42% acima do próprio normal. Vale pedir uma verificação. |
| 8 | 5539a8eedc84 | Geladeira | critico | 41 | 2026-08-23 | 14.46 | Geladeira: consumo cerca de 41% acima do próprio normal. Vale pedir uma verificação. |
| 9 | 4a35da3f69c5 | Geladeira | critico | 41 | 2026-09-13 | 15.29 | Geladeira: consumo cerca de 41% acima do próprio normal. Vale pedir uma verificação. |
| 10 | ebda85871626 | Geladeira | critico | 40 | 2026-08-23 | 14.06 | Geladeira: consumo cerca de 40% acima do próprio normal. Vale pedir uma verificação. |
| 11 | ad9ed59c3bac | Freezer | critico | 40 | 2026-10-11 | 21.03 | Freezer: consumo cerca de 40% acima do próprio normal. Vale pedir uma verificação. |
| 12 | 9b83c7a0c3a2 | Geladeira | critico | 39 | 2026-09-08 | 12.45 | Geladeira: consumo cerca de 39% acima do próprio normal. Vale pedir uma verificação. |

**Figura 8.** `mvp_alertas_aparelho`, tabela da Ouro usada pela tela de alertas.




**Figura 9.** Exportação das tabelas `mvp_*` para o JSON consumido pela tela.

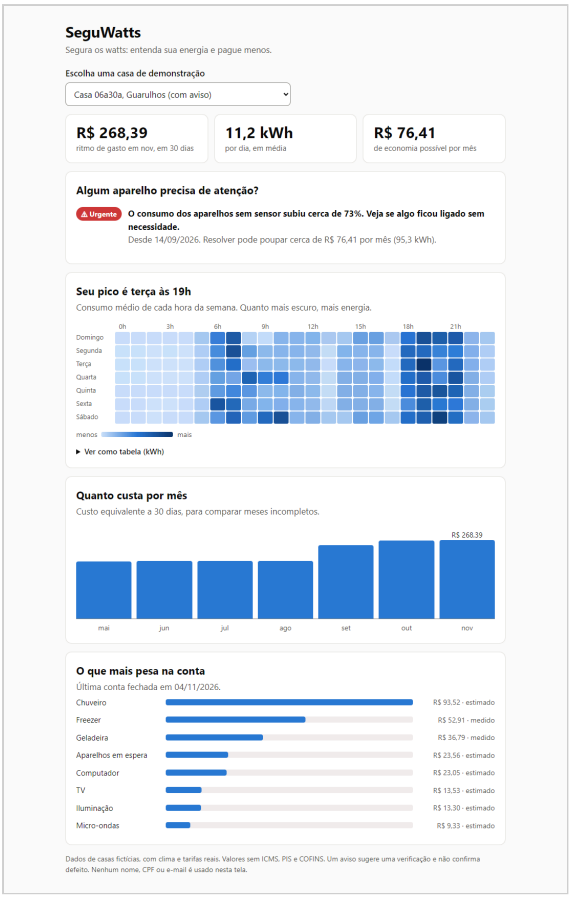



**Figura 10.** Tela do cidadão: alerta, horário de pico, custo mensal e peso de cada aparelho.

## Requisito 09: README e organização do repositório

Repositório público em https://github.com/luanmacea/seguwatts-bigdata, com `dags/`, `databricks/`, `amostras/`, `mvp/`, testes e README com integrantes, arquitetura e passo a passo de reprodução. Sem chaves, senhas ou dados pessoais reais.

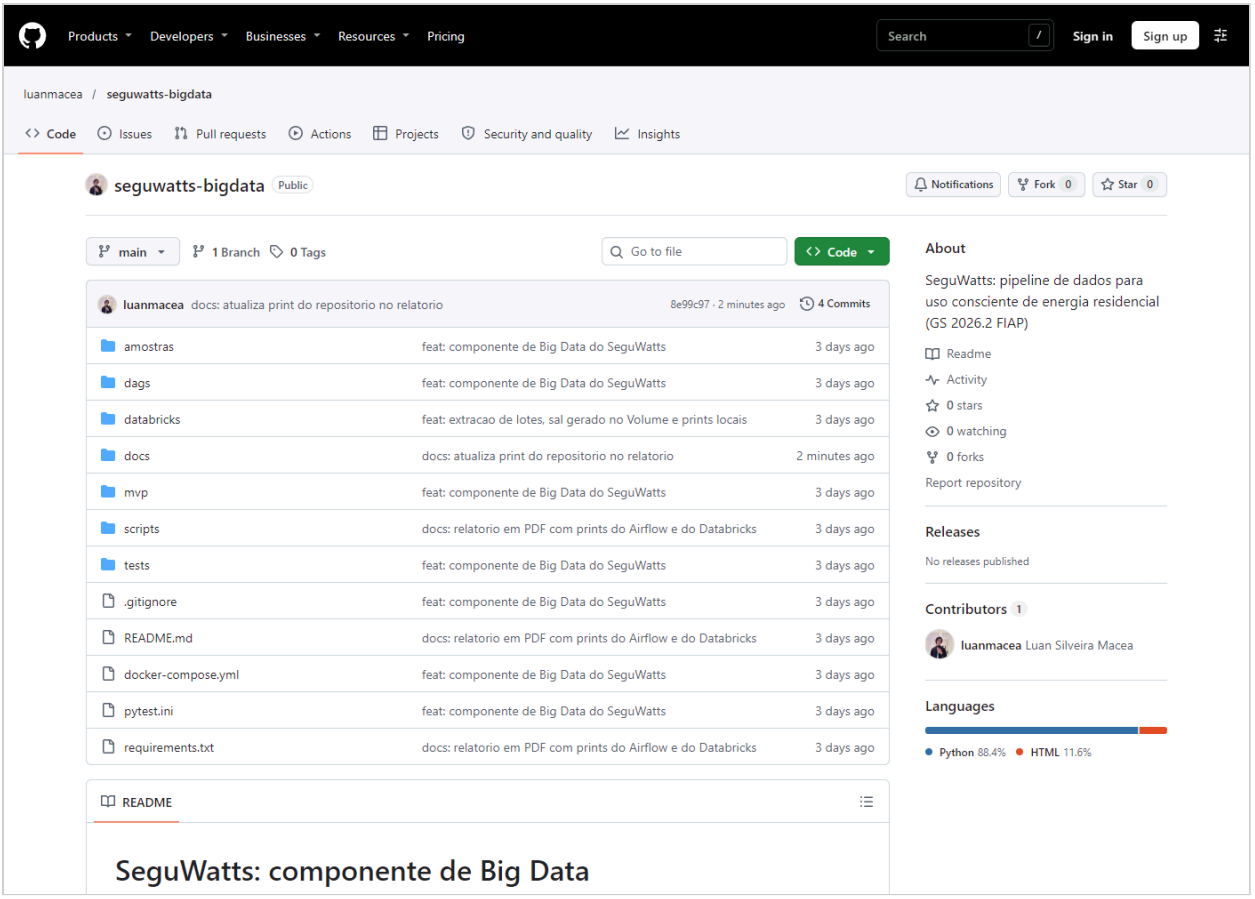



**Figura 11.** Repositório público no GitHub.

# 06. Prints do Airflow

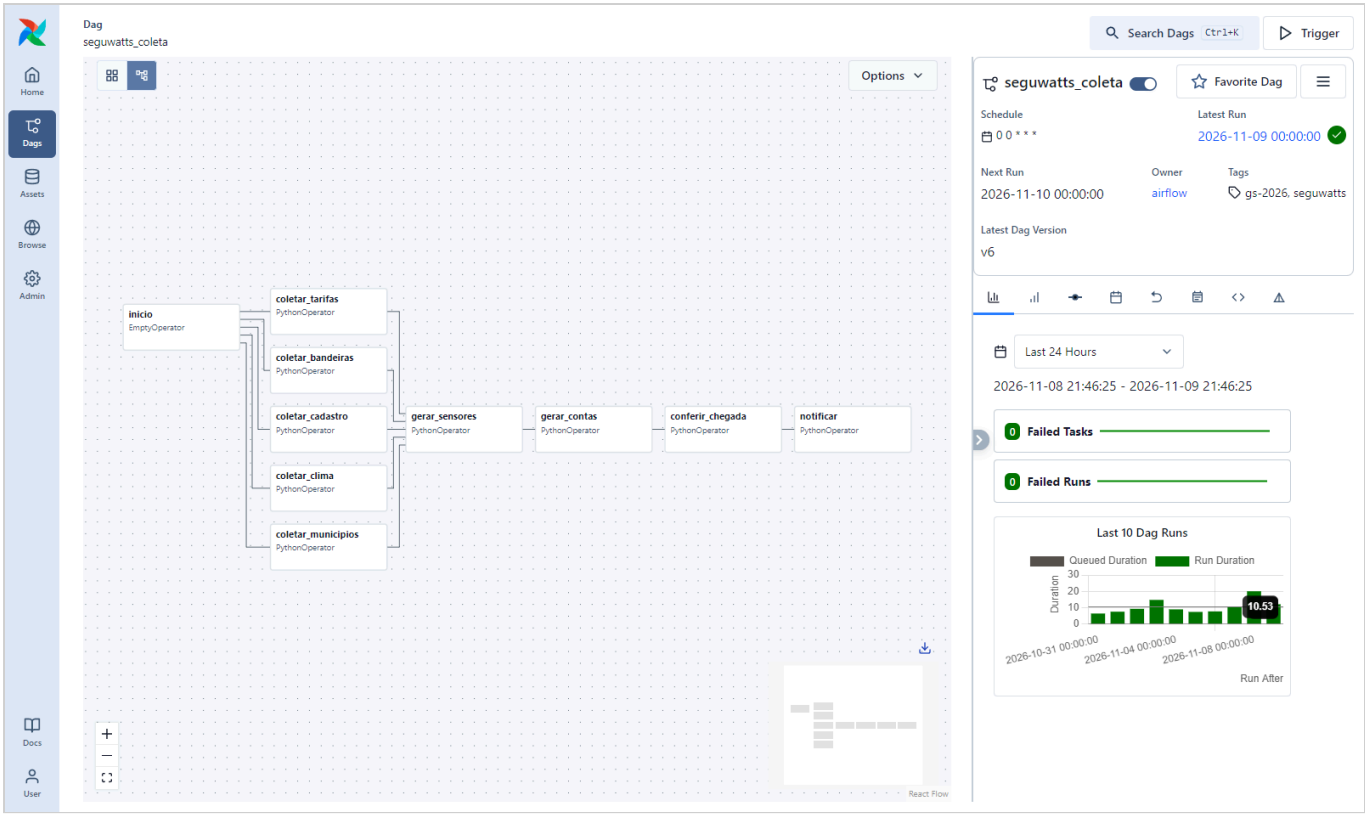



**Figura 12.** Visão Graph: `inicio`, cinco coletas em paralelo, sensores, contas, conferência e notificação.

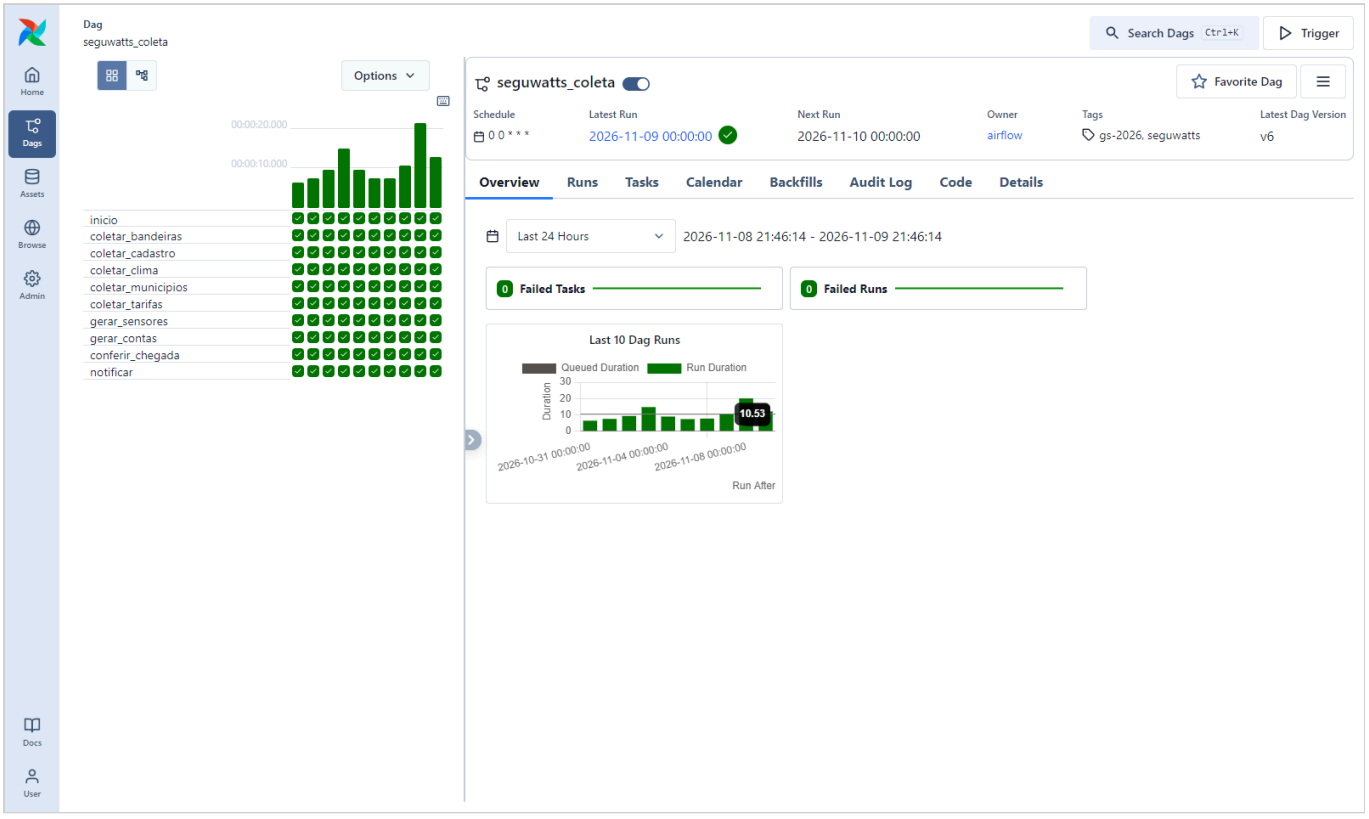



**Figura 13.** Visão Grid: execuções diárias concluídas, todas as tarefas em verde.

## 07. Contagens da Bronze

| Momento | bronze_sensores | bronze_clima | bronze_contas | Arquivos de sensores |
|---|---|---|---|---|
| Depois do lote 1 | 1.183.854 | 1.104 | 508 | 184 |
| Depois do lote 2 | 1.235.331 | 1.152 | 532 | 192 |
| 3ª execução, sem lote novo | 1.235.331 | 1.152 | 532 | 192 |

O lote 2 acrescentou só os 8 dias novos, e a execução sem lote novo não mudou nenhuma contagem: a Bronze é incremental e não duplica.

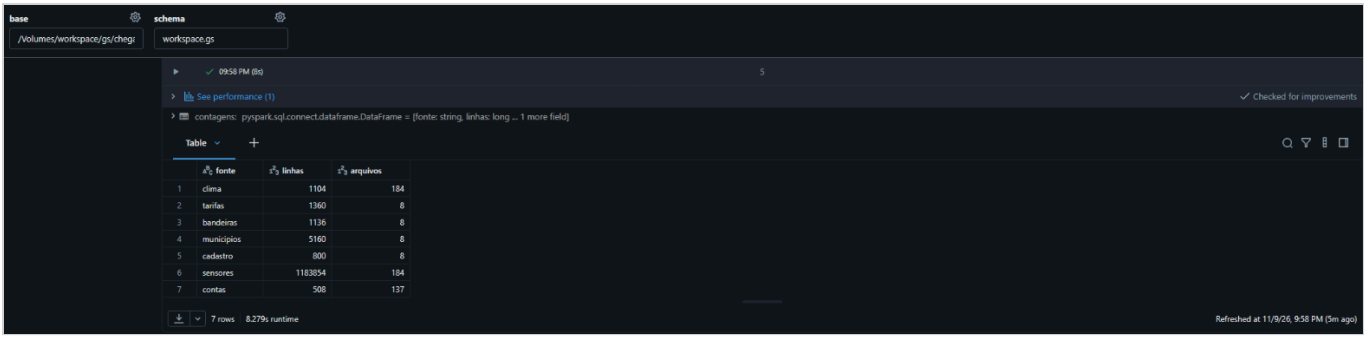



**Figura 14.** Contagens da Bronze depois do lote 1.

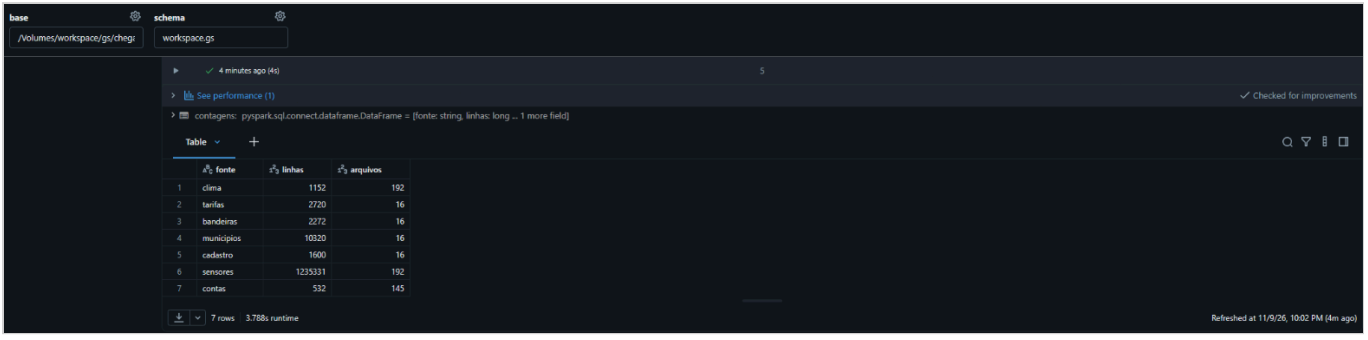



**Figura 15.** Contagens da Bronze depois do lote 2.

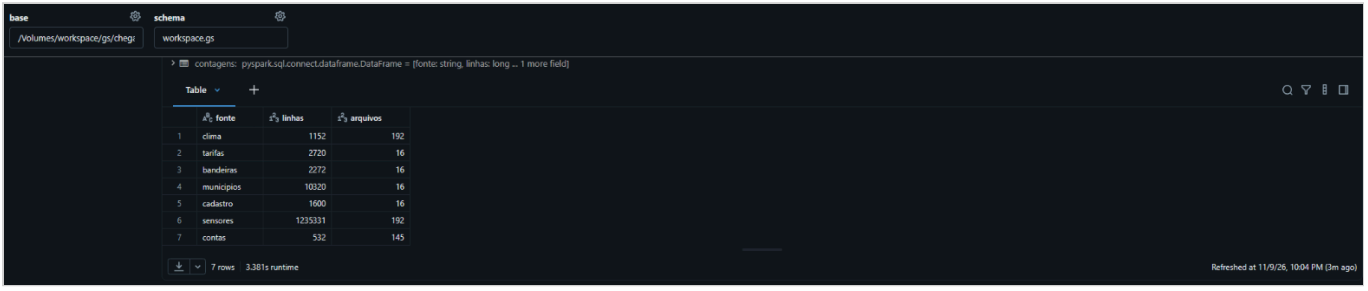



**Figura 16.** Contagens da Bronze na execução seguinte, sem lote novo: valores idênticos.

# 08. Consultas SQL, resultados e interpretação

## q1: em que dia da semana e horário as casas gastam mais?

```
-- q1: Em que dia da semana e horário as casas gastam mais?
SELECT dia_semana, hora, round(avg(kwh_medio), 3) AS kwh_medio_por_casa
FROM workspace.gs.mvp_perfil_semana
GROUP BY dia_semana, hora
ORDER BY kwh_medio_por_casa DESC
LIMIT 10;
```

Table +

| | dia_semana | hora | 1.2 kwh_medio_por_casa |
|---|---|---|---|
| 1 | Quarta | 19 | 0.84 |
| 2 | Segunda | 19 | 0.838 |
| 3 | Sábado | 19 | 0.828 |
| 4 | Domingo | 19 | 0.827 |
| 5 | Quinta | 19 | 0.824 |
| 6 | Terça | 19 | 0.819 |
| 7 | Sexta | 19 | 0.818 |
| 8 | Domingo | 20 | 0.789 |
| 9 | Sábado | 21 | 0.769 |
| 10 | Sábado | 20 | 0.761 |

**Figura 17.** q1: as dez combinações de dia e hora com maior consumo médio por casa.

O pico é às 19h em todos os dias da semana, com 0,84 kWh por casa na quarta-feira. O início da noite concentra banho, TV e iluminação, e é o melhor horário para orientar mudanças de hábito.

## q2: como o gasto muda de mês para mês?

```
-- q2: Como o gasto muda de mês para mês, com o calor e a bandeira?
SELECT p.ano_mes,
       first(p.bandeira) AS bandeira,
       round(avg(p.temperatura_media), 1) AS temperatura_media,
       round(avg(p.kwh_total / p.dias_medidos), 2) AS kwh_dia_por_casa,
       round(avg(p.custo_rs / p.dias_medidos) * 30, 2) AS custo_30_dias_por_casa
FROM workspace.gs.mvp_painel_mensal p
GROUP BY p.ano_mes
ORDER BY p.ano_mes;
```

Table +

| | ano_mes | bandeira | 1.2 temperatura_media | 1.2 kwh_dia_por_casa | 1.2 custo_30_dias_por_casa |
|---|---|---|---|---|---|
| 1 | 2026-05 | Amarela | 19.2 | 7.65 | 177.25 |
| 2 | 2026-06 | Amarela | 16.9 | 7.55 | 174.99 |
| 3 | 2026-07 | Amarela | 17.6 | 7.7 | 182.13 |
| 4 | 2026-08 | Amarela | 20.7 | 8.08 | 191.55 |
| 5 | 2026-09 | Amarela | 19.4 | 7.97 | 189.04 |
| 6 | 2026-10 | Verde | 20.4 | 7.7 | 178.48 |
| 7 | 2026-11 | Não publicada | 22.5 | 8.12 | 189.15 |

**Figura 18.** q2: consumo diário, custo equivalente a 30 dias, temperatura e bandeira por mês.

O consumo vai de 7,55 kWh/dia por casa em junho a 8,12 em novembro. A variação é pequena porque o calor aumenta geladeira e ar-condicionado e o frio aumenta o chuveiro. A bandeira amarela de maio a setembro encareceu o kWh; a de novembro ainda não foi publicada pela ANEEL.

### q3: qual aparelho pesa mais na conta?

```
-- q3: Qual aparelho pesa mais na conta? Medido na tomada ou estimado pelo rateio.
SELECT a.rotulo,
       f.origem_medicao,
       round(sum(f.kwh), 0) AS kwh_total,
       round(sum(f.custo_rs), 2) AS custo_total_rs,
       round(100 * sum(f.kwh) / sum(sum(f.kwh)) OVER (), 1) AS participacao_pct
FROM workspace.gs.fato_rateio_ciclo f
JOIN workspace.gs.dim_aparelho a USING (sk_aparelho)
GROUP BY a.rotulo, f.origem_medicao
ORDER BY kwh_total DESC;
```

Table

| | rotulo | origem_medicao | kwh_total | custo_total_rs | participacao_pct |
|---|---|---|---|---|---|
| 1 | Chuveiro | estimado | 43930 | 34369.56 | 36.8 |
| 2 | Geladeira | medido | 21127 | 16498.43 | 17.7 |
| 3 | Aparelhos em espe... | estimado | 11656 | 9118.27 | 9.8 |
| 4 | Freezer | medido | 9060 | 7083.29 | 7.6 |
| 5 | Iluminação | estimado | 8153 | 6378.64 | 6.8 |
| 6 | TV | estimado | 7531 | 5890.05 | 6.3 |
| 7 | Computador | estimado | 4453 | 3484.41 | 3.7 |
| 8 | Máquina de lavar | estimado | 4026 | 3150.91 | 3.4 |
| 9 | Ar-condicionado | medido | 3958 | 3065.49 | 3.3 |
| 10 | Micro-ondas | estimado | 3855 | 3018.21 | 3.2 |
| 11 | Ferro de passar | estimado | 1626 | 1274.96 | 1.4 |

**Figura 19.** q3: participação de cada aparelho no consumo, medido na tomada ou estimado pelo rateio da conta.

O chuveiro responde por 36,8% do consumo (estimado) e a geladeira por 17,7% (medido). O chuveiro é o maior peso, mas a geladeira é o maior consumo medido e o alvo mais claro de manutenção.

### q4: algum aparelho está gastando mais do que deveria?

```
-- q4: Quais aparelhos estão gastando mais do que deveriam?
SELECT rotulo, status, count(*) AS aparelhos, round(avg(excesso_pct), 0) AS excesso_medio_pct,
       round(avg(rs_excesso_mes), 2) AS rs_excesso_medio_mes
FROM workspace.gs.mvp_alertas_aparelho
GROUP BY rotulo, status
ORDER BY rotulo, status;
```

Table +

| | rotulo | status | aparelhos | excesso_medio_pct | rs_excesso_medio_mes |
|---|---|---|---|---|---|
| 1 | Ar-condicionado | normal | 22 | null | null |
| 2 | Ar-condicionado | sem_base | 16 | null | null |
| 3 | Demais aparelh... | atencao | 2 | 33 | 44.52 |
| 4 | Demais aparelh... | critico | 3 | 68 | 68.57 |
| 5 | Demais aparelh... | normal | 95 | null | null |
| 6 | Freezer | atencao | 3 | 32 | 14.16 |
| 7 | Freezer | critico | 2 | 38 | 18.8 |
| 8 | Freezer | normal | 25 | null | null |
| 9 | Geladeira | atencao | 8 | 31 | 10.28 |
| 10 | Geladeira | critico | 12 | 41 | 13.73 |
| 11 | Geladeira | normal | 80 | null | null |

**Figura 20.** q4: aparelhos por status de alerta, com excesso médio e custo extra por mês.

Há alertas em 20 geladeiras, 5 freezers e 5 casas com consumo sem explicação nos aparelhos sem sensor. Cada aparelho é comparado com ele mesmo nos 30 primeiros dias de uso, descontando a temperatura. Os 16 aparelhos de ar-condicionado sem 30 dias de uso ficam como `sem_base` e não geram alerta sem fundamento.

## q5 (impacto): quanto as famílias economizam?

```
-- q5 (IMPACTO): Quanto as famílias economizam resolvendo os problemas apontados?
WITH alertas AS (
  SELECT residencia_hash, sum(kwh_excesso_mes) AS kwh_mes, sum(rs_excesso_mes) AS rs_mes
  FROM workspace.gs.mvp_alertas_aparelho
  WHERE status IN ('atencao', 'critico')
  GROUP BY residencia_hash
),
ultimo_mes AS (
  SELECT residencia_hash, kwh_total / dias_medidos * 30 AS kwh_30_dias
  FROM workspace.gs.mvp_painel_mensal
  WHERE ano_mes = (SELECT max(ano_mes) FROM workspace.gs.mvp_painel_mensal)
)
SELECT count(*) AS casas_com_alerta,
       round(sum(a.kwh_mes), 1) AS kwh_evitaveis_mes,
       round(sum(a.rs_mes), 2) AS rs_evitaveis_mes,
       round(sum(a.rs_mes) * 12, 2) AS rs_evitaveis_ano,
       round(avg(a.rs_mes), 2) AS economia_media_por_casa_mes,
       round(100 * sum(a.kwh_mes) / sum(u.kwh_30_dias), 1) AS reducao_pct_nessas_casas
FROM alertas a
JOIN ultimo_mes u USING (residencia_hash);
```

Table +

| | casas_com_alerta | kwh_evitaveis_mes | rs_evitaveis_mes | rs_evitaveis_ano | economia_media_por_casa_mes | reducao_pct_nessas_casas |
|---|---|---|---|---|---|---|
| 1 | 30 | 799.4 | 621.8 | 7461.6 | 20.73 | 10.5 |

**Figura 21.** q5: economia possível se os problemas apontados forem resolvidos.

> 30 casas com alerta poderiam deixar de gastar 799,4 kWh e R$ 621,80 por mês (R$ 7.461,60 por ano), em média R$ 20,73 por casa, uma redução de 10,5% no consumo dessas famílias.

## q6 (validação): a detecção encontra as falhas injetadas?

```
-- q6 (validação): A detecção encontra as falhas injetadas pelo simulador?
WITH total AS (
  SELECT count_if(resultado = 'verdadeiro_positivo') AS vp,
         count_if(resultado = 'falso_positivo') AS fp,
         count_if(resultado = 'falso_negativo') AS fn,
         count_if(resultado = 'verdadeiro_negativo') AS vn,
         round(avg(dias_ate_detectar), 1) AS dias_medios_ate_detectar
  FROM workspace.gs.ouro_validacao_deteccao
)
SELECT vp, fp, fn, vn,
       round(100 * try_divide(vp, vp + fp), 1) AS precisao_pct,
       round(100 * try_divide(vp, vp + fn), 1) AS cobertura_pct,
       dias_medios_ate_detectar
FROM total;
```

Table +

| | vp | fp | fn | vn | precisao_pct | cobertura_pct | dias_medios_ate_detectar |
|---|---|---|---|---|---|---|---|
| 1 | 31 | 0 | 0 | 221 | 100 | 100 | 9.9 |

**Figura 22.** q6: comparação dos alertas com o gabarito do simulador.

Foram 31 falhas detectadas, nenhum alarme falso e nenhuma perdida, em média 9,9 dias após o início. Uma das 32 falhas injetadas não pôde ser avaliada por falta de 30 dias de uso. Esse resultado vale para dados simulados, em que os defeitos são nítidos; em uso real, a taxa tende a ser menor.

## 09. Conclusão técnica

O pipeline coleta quatro fontes reais e três simuladas no Airflow, envia lotes ao Volume e trata os dados em camadas no Databricks. A Bronze é incremental e não duplica. A Prata tipa, deduplica, aplica dezesseis regras de qualidade com contagem e faz MERGE. A Ouro entrega um modelo dimensional sem contagem dupla, protege dados pessoais com hash e máscara e alimenta a tela do cidadão pelas tabelas `mvp_*`.

**Decisões principais:** sensores híbridos, porque um sensor geral lendo por hora não separa o consumo por aparelho; detecção explicável, que compara cada aparelho com ele mesmo e sugere verificação em vez de afirmar defeito; e LGPD aplicada na Ouro.

**Limitações:** sensores, contas e cadastro são simulados; o custo não inclui ICMS, PIS e COFINS; e um aparelho que já começa com defeito parece normal, porque a referência são os primeiros 30 dias de uso.

**Repositório:** https://github.com/luanmacea/seguwatts-bigdata