SeguWatts

Componente Dados: pipeline de Big Data para uso consciente de energia residencial

Nome completo	RM
Davi Passanha de Sousa Guerra	RM551605
Cauã Gonçalves de Jesus	RM97648
Luan Silveira Macea	RM98290
Rui Amorim Siqueira	RM98436
Luigi Ferrara Sinno	RM98047

Global Solution 2026.2 · FIAP · Engenharia de Software, 4º ano
Big Data Architecture & Data Integration
Repositório: https://github.com/luanmacea/seguwatts-bigdata

01. Integrantes

Nome completo	RM
Davi Passanha de Sousa Guerra	RM551605
Cauã Gonçalves de Jesus	RM97648
Luan Silveira Macea	RM98290
Rui Amorim Siqueira	RM98436
Luigi Ferrara Sinno	RM98047

02. O produto e as perguntas que o MVP responde

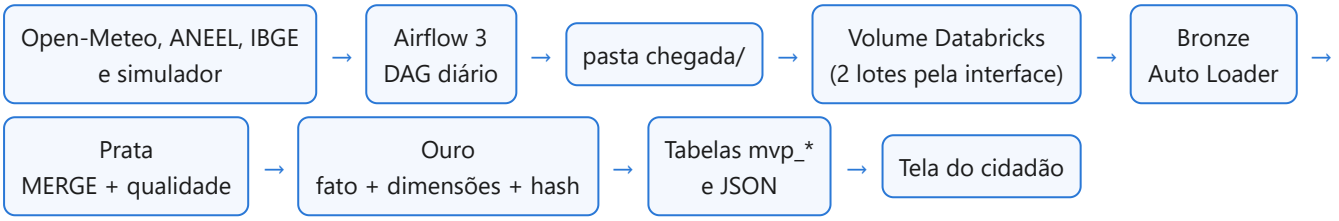
> O SeguWatts mostra ao morador quando e onde a casa gasta energia, quanto isso custa e qual aparelho pode estar com defeito, antes que o problema apareça na conta.

Cidadão: famílias de renda baixa e média no estado de São Paulo, para quem a conta de luz pesa no orçamento. **ODS:** 10 (redução das desigualdades), 11 (cidades sustentáveis) e 13 (ação climática).

#	Pergunta do cidadão	Consulta
1	Em que dia da semana e horário minha casa gasta mais?	q1
2	Como meu gasto muda de mês para mês, com o calor e a bandeira tarifária?	q2
3	Qual aparelho pesa mais na minha conta?	q3
4	Algum aparelho está gastando mais do que deveria?	q4
5	Quanto eu economizo se resolver esses problemas? (impacto)	q5

Como a casa é medida: um sensor geral no quadro de energia e sensores de tomada em até três aparelhos críticos (geladeira, freezer e ar-condicionado), todos com leitura por hora, mais a conta de luz e o cadastro de aparelhos. O consumo dos demais aparelhos é o sensor geral menos as tomadas, e cada aparelho sem sensor recebe uma parte da conta proporcional a potência × horas de uso declaradas.

03. Diagrama do fluxo de dados



O Databricks Free Edition não se conecta ao Airflow. Por isso os arquivos de `chegada/` sobem ao Volume pela interface, em lotes. Como o navegador limita o tamanho de cada envio, cada lote foi compactado (`scripts/compactar_lotes.py`) e o notebook `00b_extrair_lote` recria as pastas dentro do Volume.

04. Fontes de dados

Fonte	Origem	Formato	Frequência	Tipo
clima	Open-Meteo Archive API (6 municípios de SP)	JSON	Diária	Externa real
tarifas	ANEEL Dados Abertos: tarifas B1 residenciais	JSON	Diária	Externa real
bandeiras	ANEEL Dados Abertos: acionamento de bandeiras	JSON	Diária	Externa real
municipios	IBGE API de Localidades	JSON	Diária	Externa real
sensores	Simulador documentado (leituras horárias)	JSON	Diária	Simulada
contas	Simulador documentado (contas de luz)	JSON	Diária	Simulada
cadastro	Simulador documentado (moradores e aparelhos)	JSON aninhado	Diária	Simulada

Por que há dados simulados: não existe base aberta de consumo por residência, e dados pessoais reais não podem ser publicados. O simulador (`dags/seguwatts/simulador.py`) é reproduzível pela semente, faz a geladeira e o ar-condicionado reagirem à temperatura real do Open-Meteo, usa identidades claramente fictícias e injeta sujeira proposital e defeitos registrados num gabarito, que permitem medir se a detecção funciona.

05. Requisitos 01 a 09

Requisito 01: Duas ou mais fontes, ao menos uma externa

Quatro fontes externas reais (Open-Meteo, ANEEL tarifas, ANEEL bandeiras e IBGE) e três simuladas, todas ligadas ao problema: consumo, custo da energia e clima. Cada fonte tem uma tarefa própria no DAG.

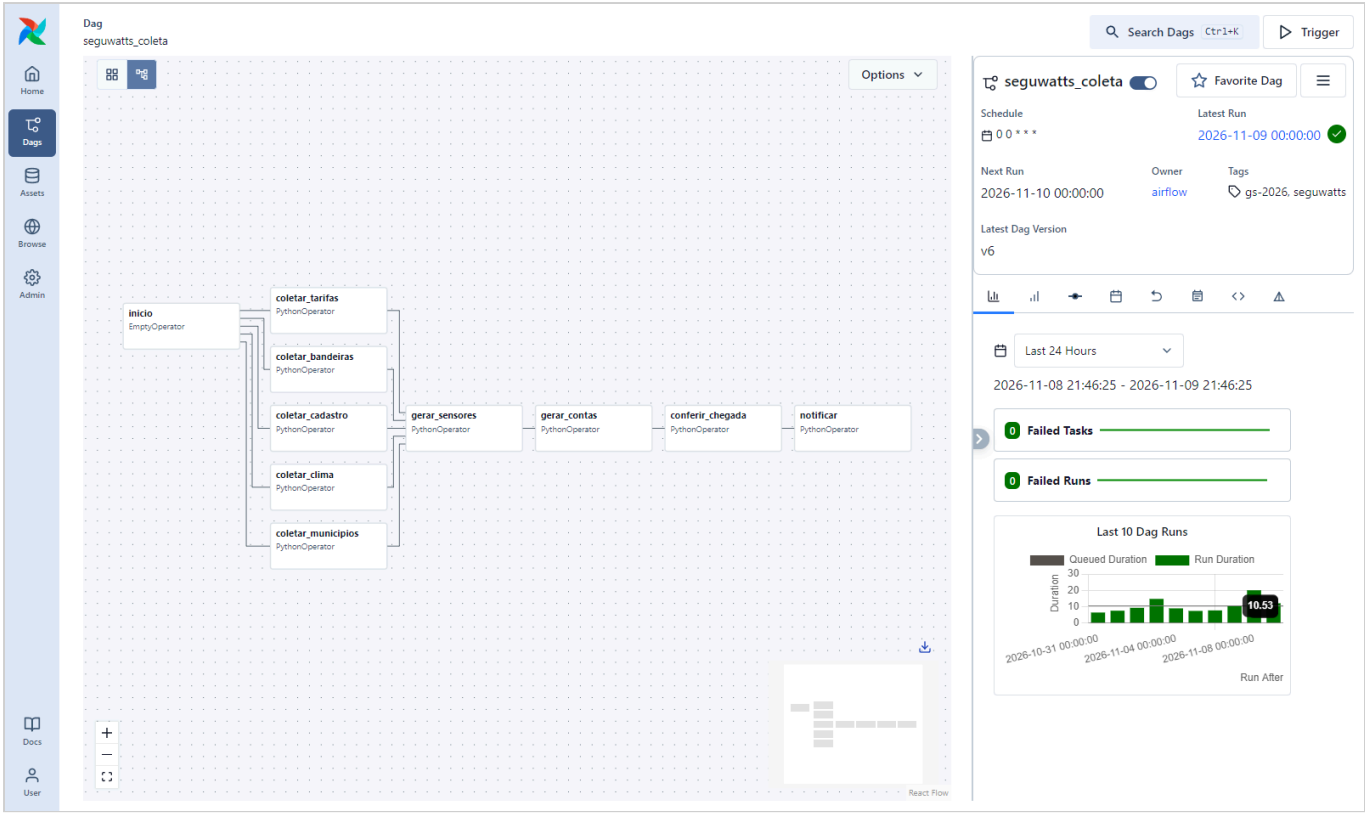


Figura 1. DAG `seguwatts_coleta` no Airflow 3: uma tarefa de coleta por fonte.

Requisito 02: DAG agendado gravando na pasta chegada/

O DAG roda `@daily` com `catchup`, coleta o dia anterior e grava um arquivo por fonte com a data no nome, por exemplo `chegada/clima/clima_2026-11-08.json`. O histórico de 01/05 a 24/10 foi gerado pelas mesmas funções (`scripts/carga_historica.py`); o DAG executou de 25/10 a 08/11, com 15 execuções concluídas.

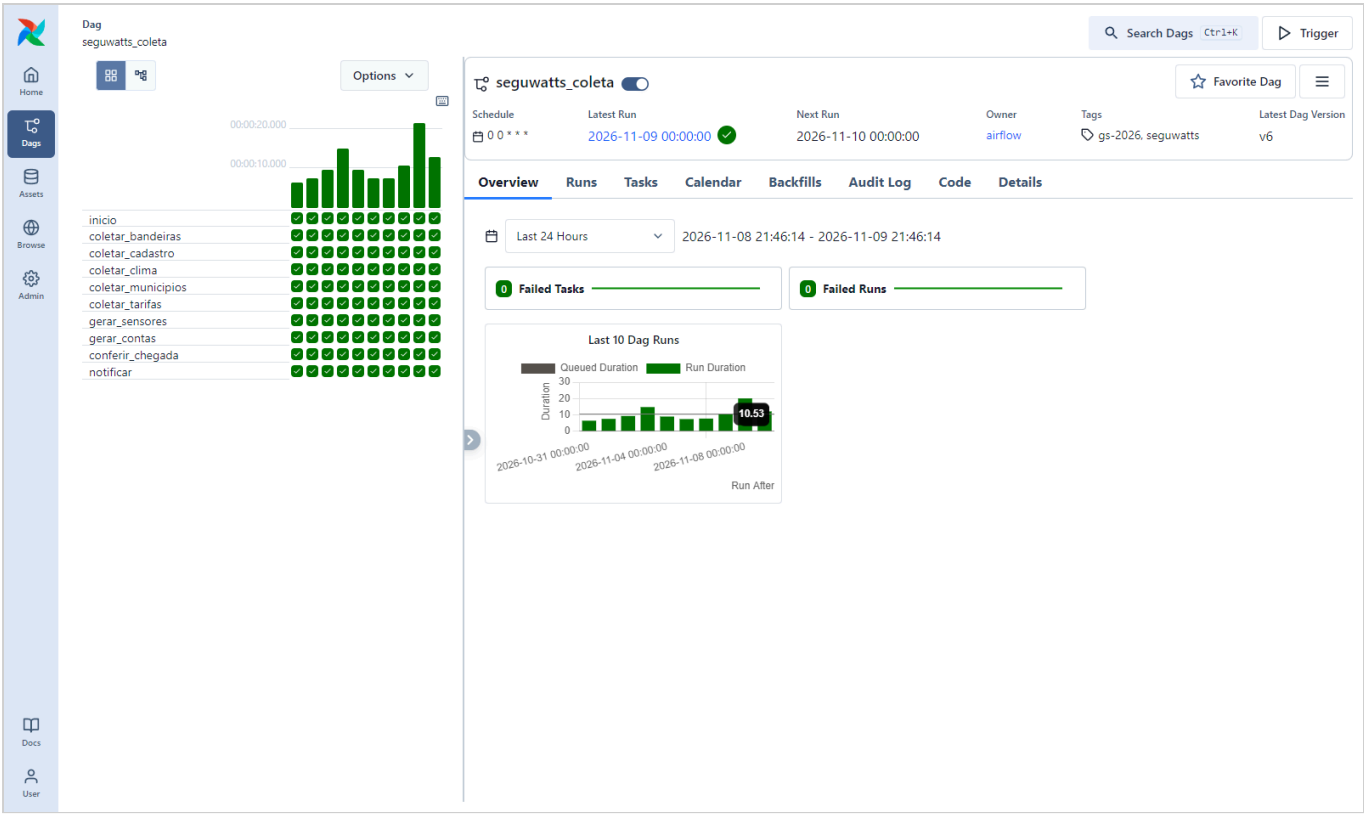


Figura 2. Visão Grid: execuções diárias concluídas com sucesso em todas as tarefas.

Requisito 03: Paralelismo, verificação dos arquivos e chaves fora do código

As cinco coletas rodam em paralelo depois de `inicio` (Figura 1). `conferir_chegada` falha se faltar algum arquivo do dia ou se uma fonte obrigatória vier vazia, e `notificar` roda sempre (`all_done`), enviando o resultado ao webhook configurado. As fontes usadas não exigem chave de API; mesmo assim, toda configuração sensível fica em Airflow Variables, nunca no código:

```
def _pasta_chegada() -> str:
    return Variable.get("seguwatts_chegada", default="/opt/airflow/chegada")

def _enviar_aviso(texto: str):
    url = Variable.get("seguwatts_webhook_url", default="")
```

Requisito 04: Dois ou mais lotes enviados ao Volume

Lote 1: dias de 01/05 a 31/10 (585 arquivos, em 2 partes compactadas). Lote 2: dias de 01/11 a 08/11 (56 arquivos). Cada lote foi enviado pela interface e extraído no Volume em momentos diferentes.

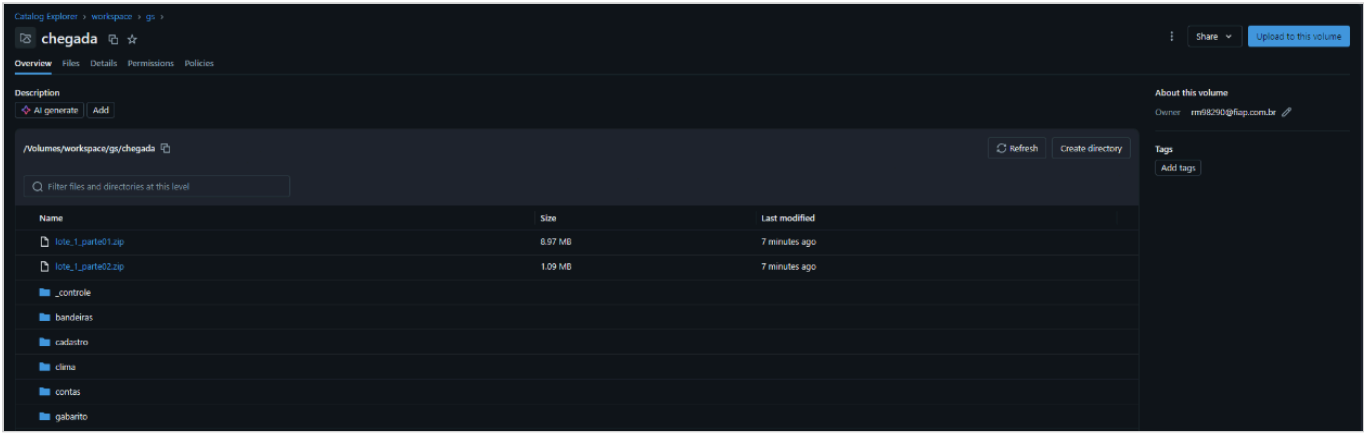


Figura 3. Volume `workspace.gs.chegada` com o lote 1 enviado e as pastas por fonte já extraídas.



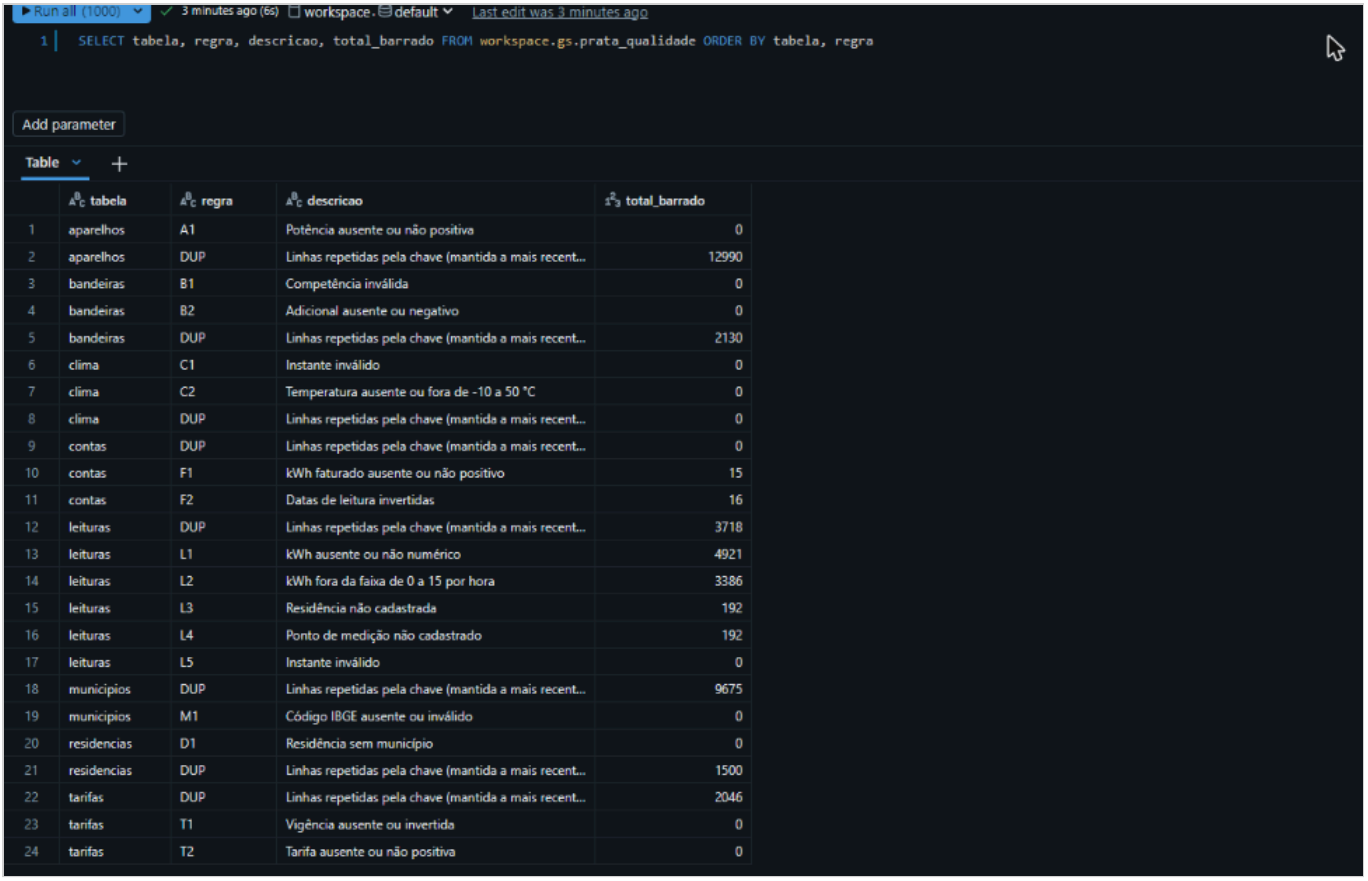
Figura 4. Extração do lote 2: 8 arquivos novos por fonte, de 01/11 a 08/11.

Requisito 05: Bronze incremental e sem duplicação

Auto Loader (`cloudFiles`, `availableNow`) com checkpoint por fonte: só arquivos novos entram. As contagens antes e depois do 2º lote e da reexecução estão na seção 07.

Requisito 06: Prata: tipos, nulos e inválidos tratados, MERGE pela chave e regras de qualidade

Cada tabela recebe tipos corretos (`try_cast`, vírgula decimal convertida), remove duplicatas pela chave e faz `MERGE`. Dezesseis regras com contagem: as linhas barradas vão para `prata_rejeitos` e os totais para `prata_qualidade`. Em `prata_leituras`, por exemplo, foram barradas 4.921 leituras sem kWh válido, 3.386 fora da faixa de 0 a 15 kWh/h, 192 de residência inexistente e 192 de ponto de medição inexistente.



```
▶ Run all (1000)  ✓ 3 minutes ago (6s)  workspace.default  Last edit was 3 minutes ago
1  SELECT tabela, regra, descricao, total_barrado FROM workspace.gs.prata_qualidade ORDER BY tabela, regra
```

Add parameter

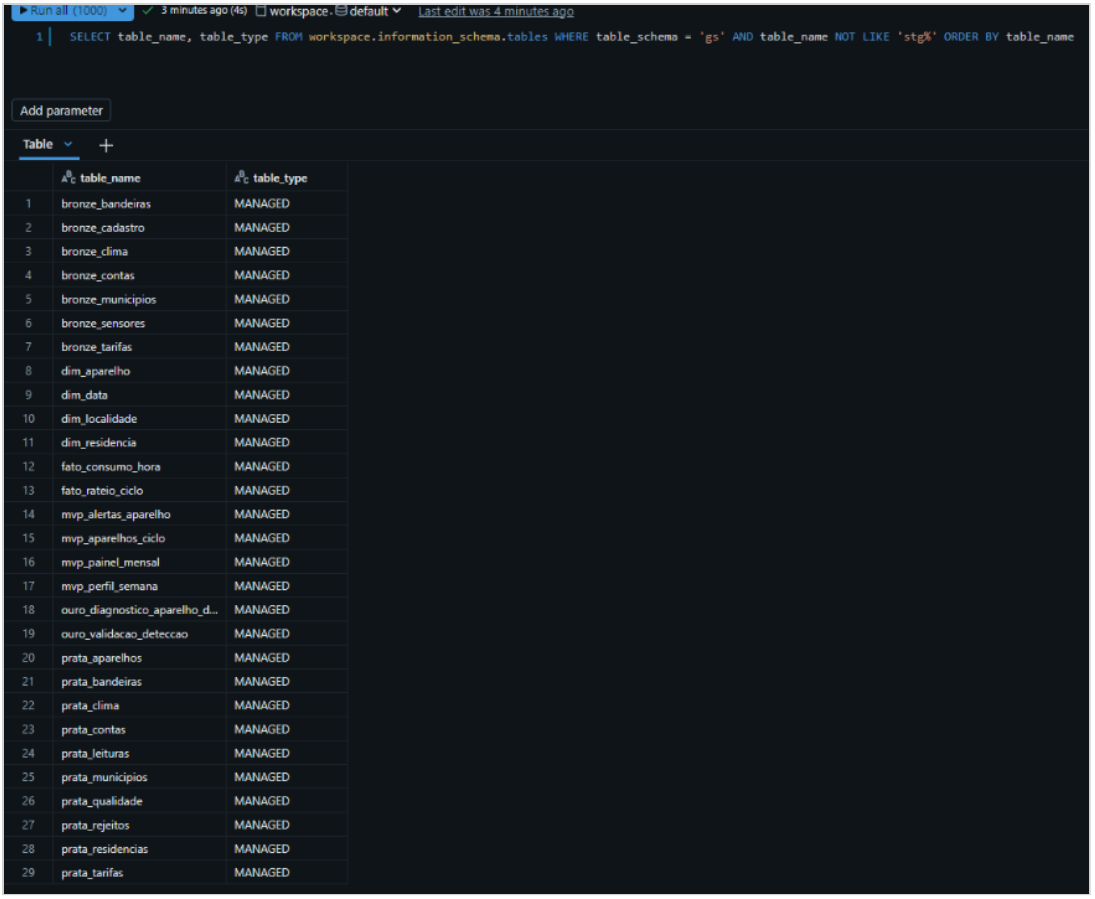
Table

	tabela	regra	descricao	total_barrado
1	aparelhos	A1	Potência ausente ou não positiva	0
2	aparelhos	DUP	Linhas repetidas pela chave (mantida a mais recent...	12990
3	bandeiras	B1	Competência inválida	0
4	bandeiras	B2	Adicional ausente ou negativo	0
5	bandeiras	DUP	Linhas repetidas pela chave (mantida a mais recent...	2130
6	clima	C1	Instante inválido	0
7	clima	C2	Temperatura ausente ou fora de -10 a 50 °C	0
8	clima	DUP	Linhas repetidas pela chave (mantida a mais recent...	0
9	contas	DUP	Linhas repetidas pela chave (mantida a mais recent...	0
10	contas	F1	kWh faturado ausente ou não positivo	15
11	contas	F2	Datas de leitura invertidas	16
12	leituras	DUP	Linhas repetidas pela chave (mantida a mais recent...	3718
13	leituras	L1	kWh ausente ou não numérico	4921
14	leituras	L2	kWh fora da faixa de 0 a 15 por hora	3386
15	leituras	L3	Residência não cadastrada	192
16	leituras	L4	Ponto de medição não cadastrado	192
17	leituras	L5	Instante inválido	0
18	municipios	DUP	Linhas repetidas pela chave (mantida a mais recent...	9675
19	municipios	M1	Código IBGE ausente ou inválido	0
20	residencias	D1	Residência sem município	0
21	residencias	DUP	Linhas repetidas pela chave (mantida a mais recent...	1500
22	tarifas	DUP	Linhas repetidas pela chave (mantida a mais recent...	2046
23	tarifas	T1	Vigência ausente ou invertida	0
24	tarifas	T2	Tarifa ausente ou não positiva	0

Figura 5. Tabela `prata_qualidade`: total barrado por regra e linhas repetidas removidas.

Requisito 07: Ouro dimensional e 5 consultas SQL

Fato `fato_consumo_hora` (residência × aparelho × hora, 1,2 milhão de linhas) e dimensões `dim_data`, `dim_localidade`, `dim_residencia` e `dim_aparelho`, além do fato `fato_rateio_ciclo`. O fato guarda as tomadas e as demais cargas, nunca o sensor geral junto, para não somar nada em dobro. As consultas estão na seção 08.



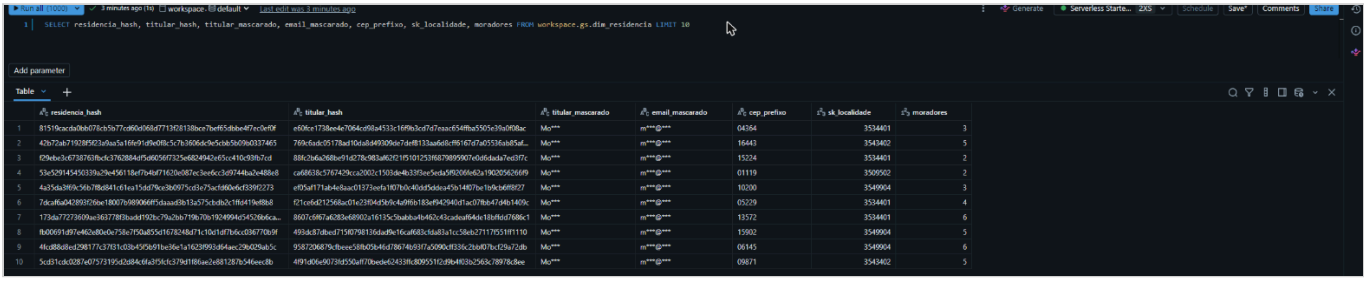
```
SELECT table_name, table_type FROM workspace.information_schema.tables WHERE table_schema = 'gs' AND table_name NOT LIKE 'stg%' ORDER BY table_name
```

	table_name	table_type
1	bronze_bandeiras	MANAGED
2	bronze_cadastro	MANAGED
3	bronze_clima	MANAGED
4	bronze_contas	MANAGED
5	bronze_municipios	MANAGED
6	bronze_sensores	MANAGED
7	bronze_tarifas	MANAGED
8	dim_aparelho	MANAGED
9	dim_data	MANAGED
10	dim_localidade	MANAGED
11	dim_residencia	MANAGED
12	fato_consumo_hora	MANAGED
13	fato_rateio_ciclo	MANAGED
14	mvp_alertas_aparelho	MANAGED
15	mvp_aparelhos_ciclo	MANAGED
16	mvp_painel_mensal	MANAGED
17	mvp_perfil_semana	MANAGED
18	ouro_diagnostico_aparelho_d...	MANAGED
19	ouro_validacao_deteccao	MANAGED
20	prata_aparelhos	MANAGED
21	prata_bandeiras	MANAGED
22	prata_clima	MANAGED
23	prata_contas	MANAGED
24	prata_leituras	MANAGED
25	prata_municipios	MANAGED
26	prata_qualidade	MANAGED
27	prata_rejeitos	MANAGED
28	prata_residencias	MANAGED
29	prata_tarifas	MANAGED

Figura 6. Tabelas do schema `workspace.gs`: Bronze, Prata, dimensões, fatos e tabelas do MVP.

Requisito 08: LGPD na Ouro e uso dos dados pelo MVP

Na Ouro não há nome, CPF, e-mail, telefone nem o identificador original. Titular e residência viram SHA-256 com sal; o sal fica no secret, no widget ou num arquivo gerado no Volume, nunca no repositório. O MVP consome apenas as tabelas `mvp_*`, exportadas em JSON (contrato em `docs/contrato_mvp.md`).



```
SELECT residencia_hash, titular_hash, titular_mascarado, email_mascarado, cep_prefixo, sk_localidade, moradores FROM workspace.gs.dim_residencia LIMIT 10
```

	residencia_hash	titular_hash	titular_mascarado	email_mascarado	cep_prefixo	sk_localidade	moradores
1	81519cacda0bb078cb5b77cd60d068d7713f08138bce7bef65dbbe4f7ec0ef0f	e606ce1738ee4e7064cd98a4533c16f8b3cd7d7eaacf654ffba5505e39a0f0bac	Mo***	m***@***	04364	3534401	3
2	42b72ab71928f5f23a9aa5a16fe91d9e08c5c7b3606dc9e5cbb5b09b0337465	769c6adc05178ad10da8d49309de7dfeff8133aa6e8cff6167d7a01536a8d5af...	Mo***	m***@***	16443	3543402	5
3	f29ebe3c67383763fbcfc3762884df5d60569f7325e6824942e65cc410c93fb7cd	886c2b6a268be91d278c983a662f21f5101253f68789895907e0d6dada7ed3f7c	Mo***	m***@***	15224	3534401	2
4	53e529145456339a29e45618ef7b4bf71620e087ec3ee6cc3d9744ba2e488e8	ca68638c5767429cca2002c1503de4b33f3ee5eda5ff0266b62a1902056266f9	Mo***	m***@***	01119	3509502	2
5	4a35da3f69c56b78bd841c61ea15dd78cc3b0975cd3e75acfd60e6ef339f2273	ef05af171ab4e8aac01373eefa107bb040dd5ddec45b14407be1b9cbe6f6f827	Mo***	m***@***	10200	3549904	3
6	7dcaf6a042893f69ee18007b989066ff5daaad3b13a575cbdb2c1f6f419ef8b8	f21cef62125568c01e23f04d5bf6c4a0f6b182ef942940d1ac078bb47d4b1409c	Mo***	m***@***	05229	3534401	4
7	173da772736b9ae163778f3badd1928bc79a2bb719b70b192499d54526b6ca...	8607c6f67a6283e689024a16135c5babba4b462c43cadeaf64de18bf8dd768bc1	Mo***	m***@***	13572	3534401	6
8	fb00691d97e462e80e0e758e7550a855d1678248d71c10d1df7b6cd3677f0b9f	493dc87dbed715f0798136dad9e16caf683c1da83a1cc58eb27117551ff1110	Mo***	m***@***	15902	3549904	5
9	4fcd88d8ed298177c37831c03b45f0b91be36e1a1623f993d64aec29b029ab5c	9587206879cfbeee58ffb05b46d78674b937a5090cff336c2bb0f07bcf29a72db	Mo***	m***@***	06145	3549904	6
10	5cd31cdc0287e07573195d2d84c6fa3f5fcfc379df186ae2e881287b546eec8b	4f91d06e90734d550aff70bede62433ffc8095512d9b4f03b2563c78978c8ee	Mo***	m***@***	09871	3543402	5

Figura 7. `dim_residencia`: identificadores em hash, titular e e-mail mascarados, CEP com 5 dígitos.



```
SELECT left(residencia_hash, 12) AS residencia, rotulo, status, excesso_pct, desde, rs_excesso_mes, mensagem FROM workspace.gs.mvp_alertas_aparelho WHERE status IN ('atencao', 'critico') ORDER BY excesso_pct DESC LIMIT 12
```

	residencia	rotulo	status	excesso_pct	desde	rs_excesso_mes	mensagem
1	033882f719aa	Demais aparelh...	critico	73	2026-09-14	76.41	O consumo dos aparelhos sem sensor subiu cerca de 73%. Veja se algo ficou ligado sem necessidade.
2	7c1666133f60	Demais aparelh...	critico	69	2026-07-24	59.08	O consumo dos aparelhos sem sensor subiu cerca de 69%. Veja se algo ficou ligado sem necessidade.
3	09eaff855f53	Demais aparelh...	critico	61	2026-09-08	76.22	O consumo dos aparelhos sem sensor subiu cerca de 61%. Veja se algo ficou ligado sem necessidade.
4	1e9b88842eac	Geladeira	critico	45	2026-09-17	15.95	Geladeira: consumo cerca de 45% acima do próprio normal. Vale pedir uma verificação.
5	f54870ba4f76	Geladeira	critico	45	2026-08-12	14.38	Geladeira: consumo cerca de 45% acima do próprio normal. Vale pedir uma verificação.
6	fedc42bfe580	Geladeira	critico	44	2026-08-25	14.31	Geladeira: consumo cerca de 44% acima do próprio normal. Vale pedir uma verificação.
7	7ffe6f5b2224	Geladeira	critico	42	2026-09-06	13.64	Geladeira: consumo cerca de 42% acima do próprio normal. Vale pedir uma verificação.
8	5539a8eedc84	Geladeira	critico	41	2026-08-23	14.46	Geladeira: consumo cerca de 41% acima do próprio normal. Vale pedir uma verificação.
9	4a35da3f69c5	Geladeira	critico	41	2026-09-13	15.29	Geladeira: consumo cerca de 41% acima do próprio normal. Vale pedir uma verificação.
10	ebda85871626	Geladeira	critico	40	2026-08-23	14.06	Geladeira: consumo cerca de 40% acima do próprio normal. Vale pedir uma verificação.
11	ad9ed59c3bac	Freezer	critico	40	2026-10-11	21.03	Freezer: consumo cerca de 40% acima do próprio normal. Vale pedir uma verificação.
12	9b83c7a0c3a2	Geladeira	critico	39	2026-09-08	12.45	Geladeira: consumo cerca de 39% acima do próprio normal. Vale pedir uma verificação.

Figura 8. `mvp_alertas_aparelho`, tabela da Ouro usada pela tela de alertas.



Figura 9. Exportação das tabelas `mvp_*` para o JSON consumido pela tela.

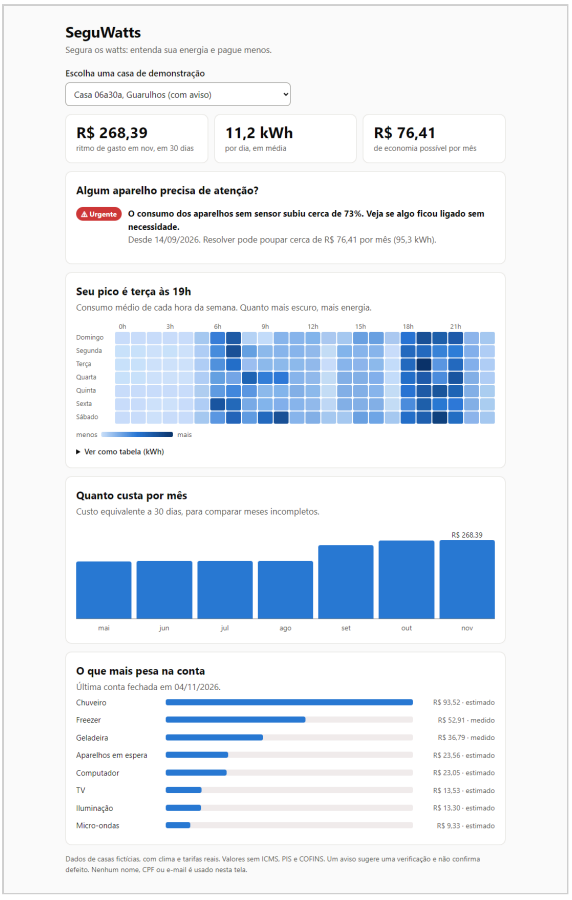


Figura 10. Tela do cidadão: alerta, horário de pico, custo mensal e peso de cada aparelho.

Requisito 09: README e organização do repositório

Repositório público em https://github.com/luanmacea/seguwatts-bigdata, com `dags/`, `databricks/`, `amostras/`, `mvp/`, testes e README com integrantes, arquitetura e passo a passo de reprodução. Sem chaves, senhas ou dados pessoais reais.

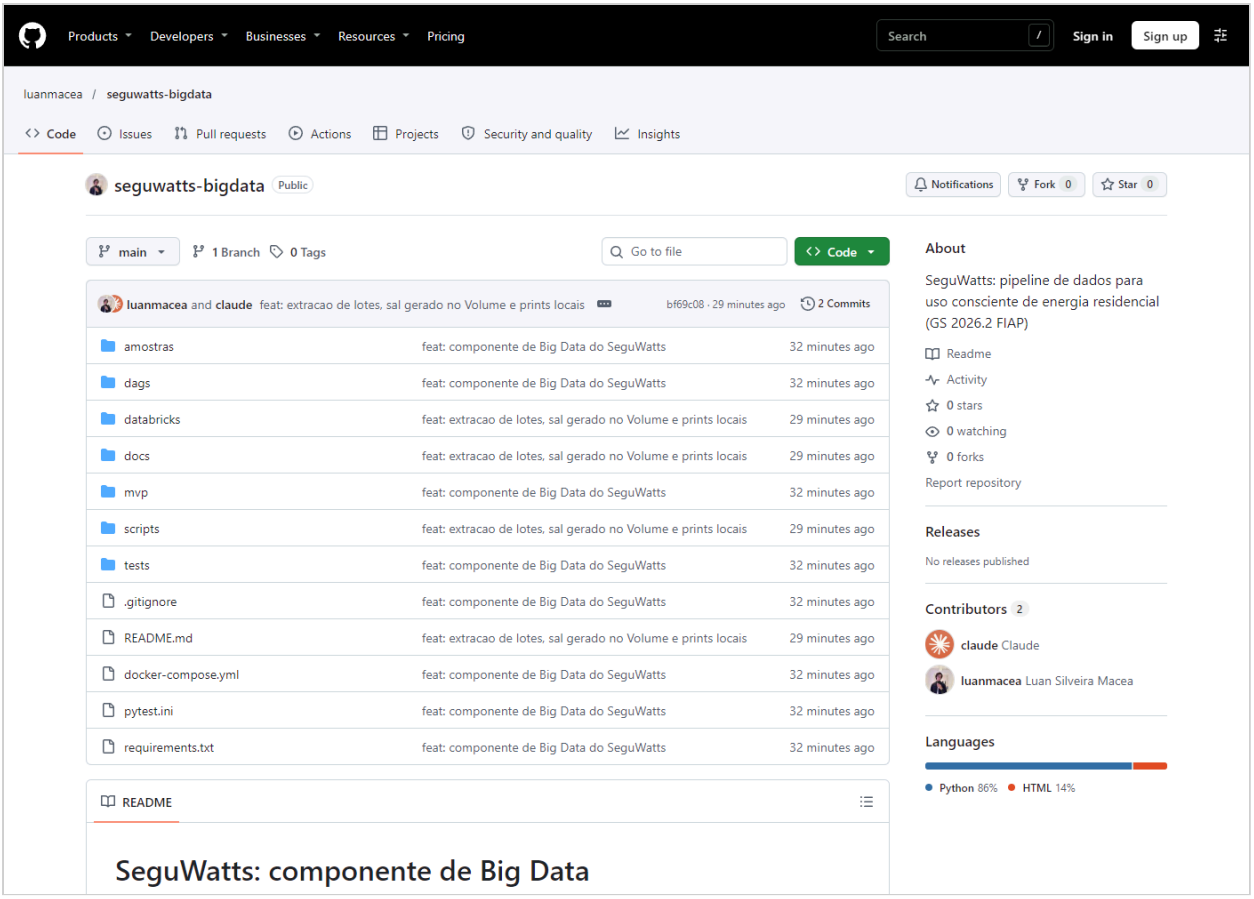


Figura 11. Repositório público no GitHub.

06. Prints do Airflow

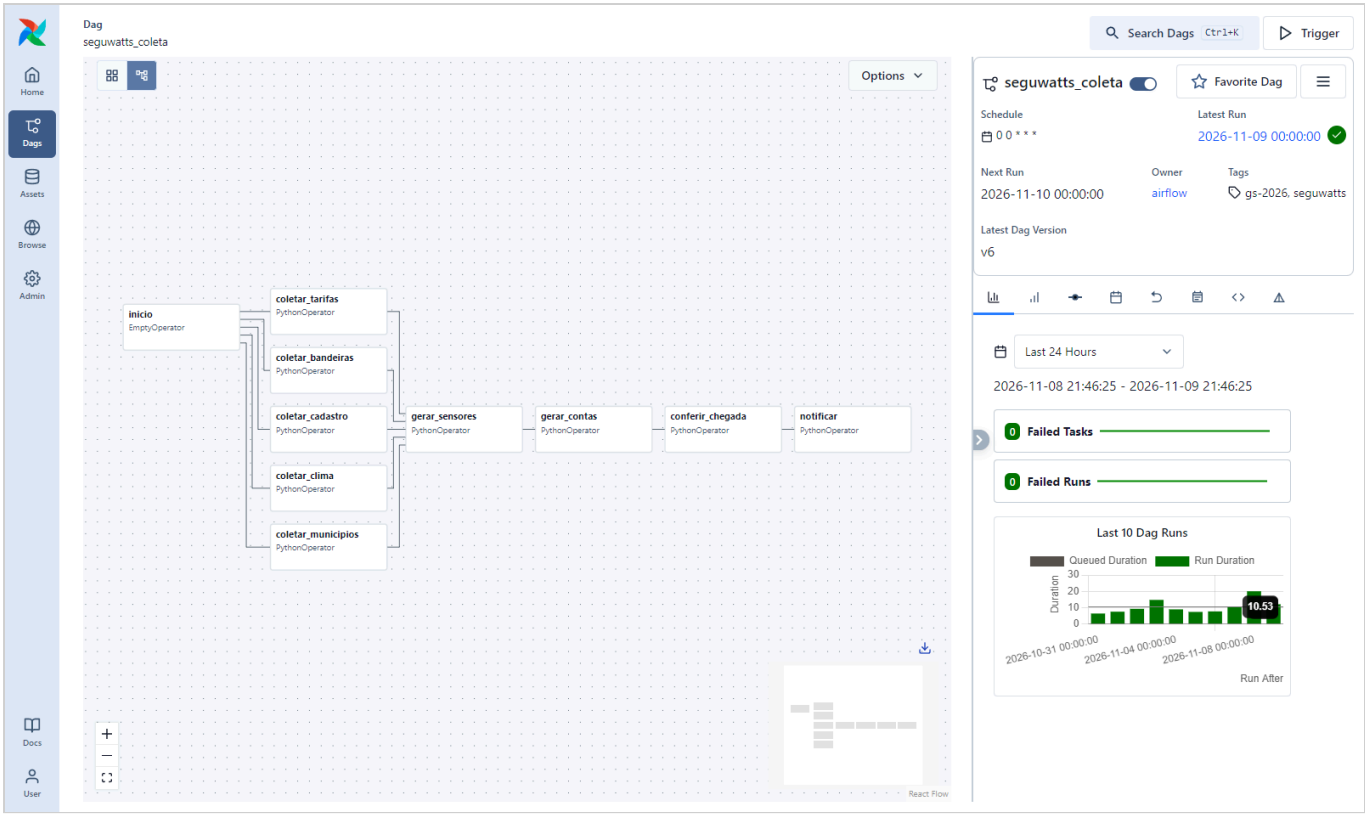


Figura 12. Visão Graph: `inicio`, cinco coletas em paralelo, sensores, contas, conferência e notificação.

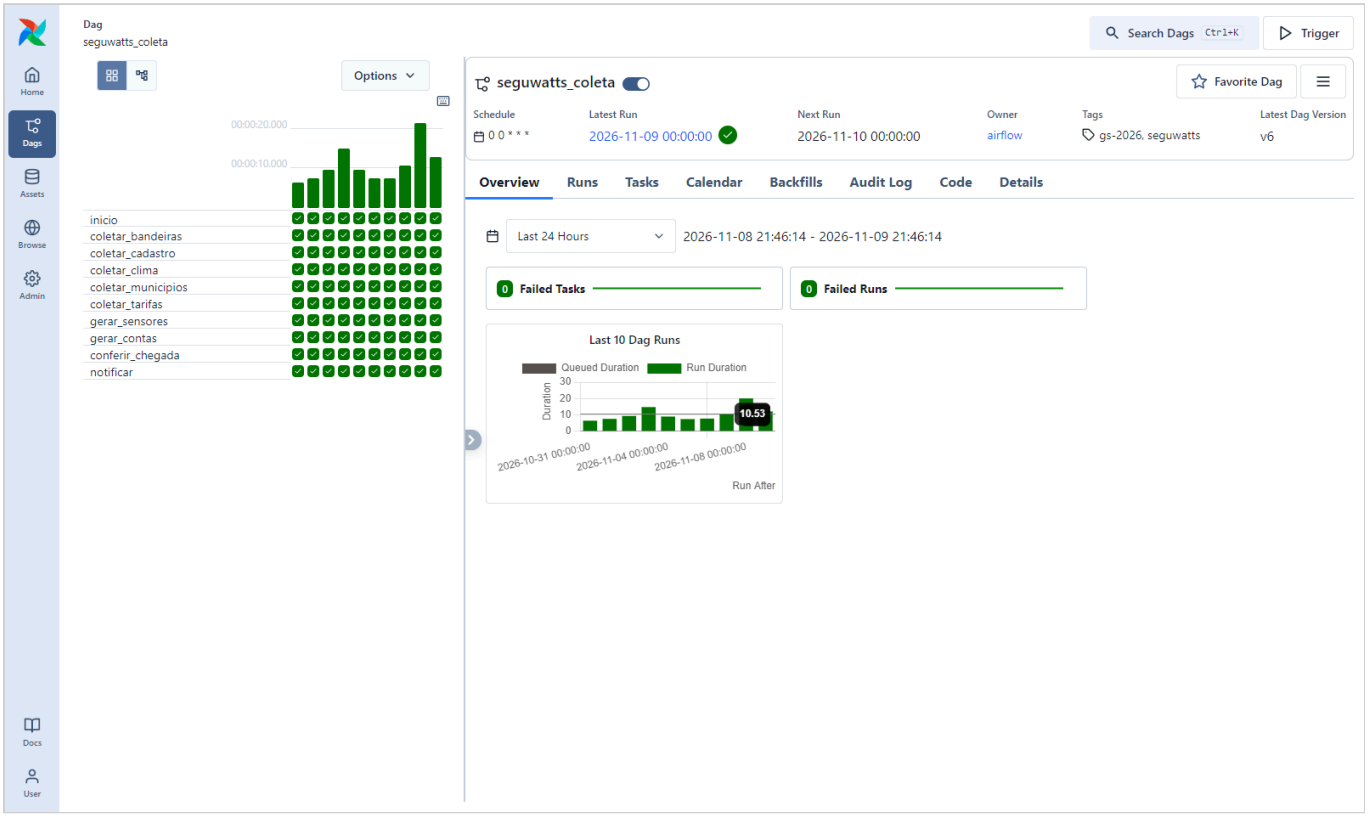


Figura 13. Visão Grid: execuções diárias concluídas, todas as tarefas em verde.

07. Contagens da Bronze

Momento	bronze_sensores	bronze_clima	bronze_contas	Arquivos de sensores
Depois do lote 1	1.183.854	1.104	508	184
Depois do lote 2	1.235.331	1.152	532	192
3ª execução, sem lote novo	1.235.331	1.152	532	192

O lote 2 acrescentou só os 8 dias novos, e a execução sem lote novo não mudou nenhuma contagem: a Bronze é incremental e não duplica.

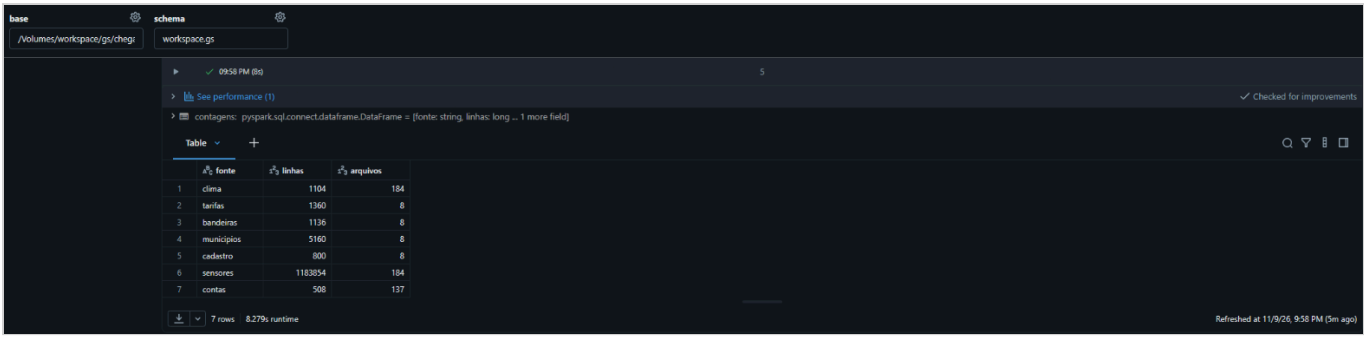


Figura 14. Contagens da Bronze depois do lote 1.

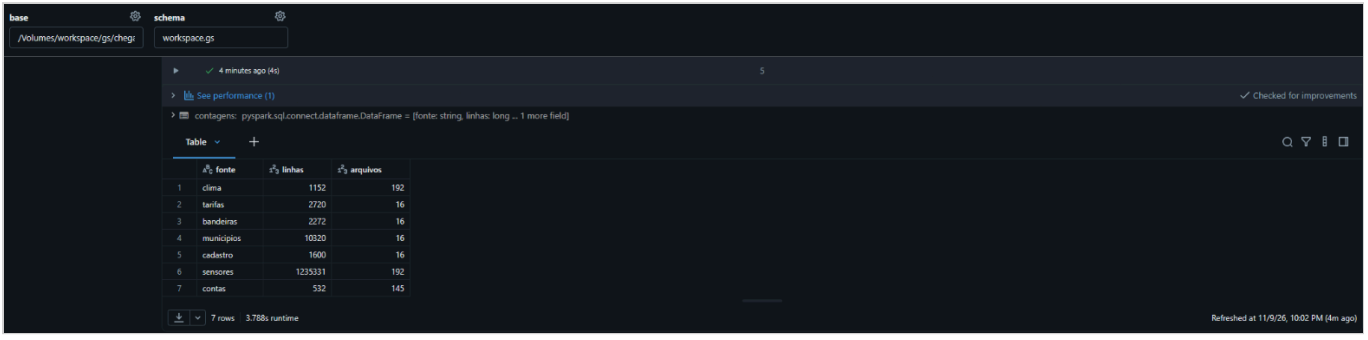


Figura 15. Contagens da Bronze depois do lote 2.

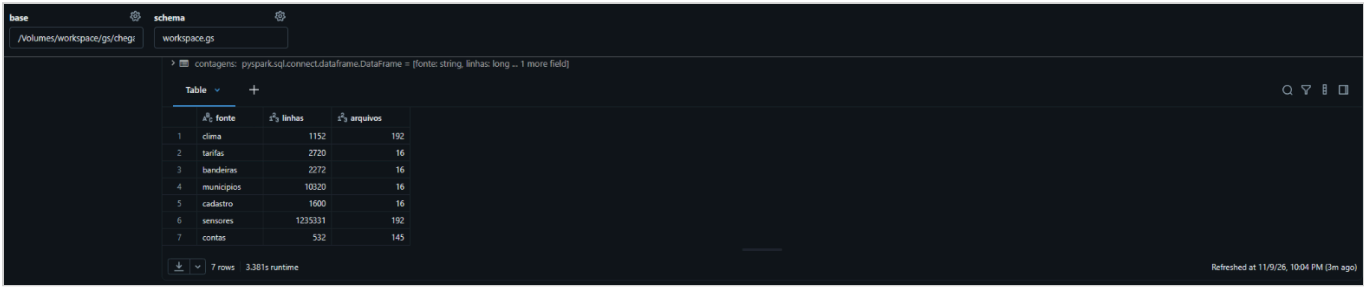


Figura 16. Contagens da Bronze na execução seguinte, sem lote novo: valores idênticos.

08. Consultas SQL, resultados e interpretação

q1: em que dia da semana e horário as casas gastam mais?

```
-- q1: Em que dia da semana e horário as casas gastam mais?
SELECT dia_semana, hora, round(avg(kwh_medio), 3) AS kwh_medio_por_casa
FROM workspace.gs.mvp_perfil_semana
GROUP BY dia_semana, hora
ORDER BY kwh_medio_por_casa DESC
LIMIT 10;
```

Table +

	dia_semana	hora	1.2 kwh_medio_por_casa
1	Quarta	19	0.84
2	Segunda	19	0.838
3	Sábado	19	0.828
4	Domingo	19	0.827
5	Quinta	19	0.824
6	Terça	19	0.819
7	Sexta	19	0.818
8	Domingo	20	0.789
9	Sábado	21	0.769
10	Sábado	20	0.761

Figura 17. q1: as dez combinações de dia e hora com maior consumo médio por casa.

O pico é às 19h em todos os dias da semana, com 0,84 kWh por casa na quarta-feira. O início da noite concentra banho, TV e iluminação, e é o melhor horário para orientar mudanças de hábito.

q2: como o gasto muda de mês para mês?

```
-- q2: Como o gasto muda de mês para mês, com o calor e a bandeira?
SELECT p.ano_mes,
       first(p.bandeira) AS bandeira,
       round(avg(p.temperatura_media), 1) AS temperatura_media,
       round(avg(p.kwh_total / p.dias_medidos), 2) AS kwh_dia_por_casa,
       round(avg(p.custo_rs / p.dias_medidos) * 30, 2) AS custo_30_dias_por_casa
FROM workspace.gs.mvp_painel_mensal p
GROUP BY p.ano_mes
ORDER BY p.ano_mes;
```

Table +

	ano_mes	bandeira	1.2 temperatura_media	1.2 kwh_dia_por_casa	1.2 custo_30_dias_por_casa
1	2026-05	Amarela	19.2	7.65	177.25
2	2026-06	Amarela	16.9	7.55	174.99
3	2026-07	Amarela	17.6	7.7	182.13
4	2026-08	Amarela	20.7	8.08	191.55
5	2026-09	Amarela	19.4	7.97	189.04
6	2026-10	Verde	20.4	7.7	178.48
7	2026-11	Não publicada	22.5	8.12	189.15

Figura 18. q2: consumo diário, custo equivalente a 30 dias, temperatura e bandeira por mês.

O consumo vai de 7,55 kWh/dia por casa em junho a 8,12 em novembro. A variação é pequena porque o calor aumenta geladeira e ar-condicionado e o frio aumenta o chuveiro. A bandeira amarela de maio a setembro encareceu o kWh; a de novembro ainda não foi publicada pela ANEEL.

q3: qual aparelho pesa mais na conta?

```
-- q3: Qual aparelho pesa mais na conta? Medido na tomada ou estimado pelo rateio.
SELECT a.rotulo,
       f.origem_medicao,
       round(sum(f.kwh), 0) AS kwh_total,
       round(sum(f.custo_rs), 2) AS custo_total_rs,
       round(100 * sum(f.kwh) / sum(sum(f.kwh)) OVER (), 1) AS participacao_pct
FROM workspace.gs.fato_rateio_ciclo f
JOIN workspace.gs.dim_aparelho a USING (sk_aparelho)
GROUP BY a.rotulo, f.origem_medicao
ORDER BY kwh_total DESC;
```

Table

	rotulo	origem_medicao	kwh_total	custo_total_rs	participacao_pct
1	Chuveiro	estimado	43930	34369.56	36.8
2	Geladeira	medido	21127	16498.43	17.7
3	Aparelhos em espe...	estimado	11656	9118.27	9.8
4	Freezer	medido	9060	7083.29	7.6
5	Iluminação	estimado	8153	6378.64	6.8
6	TV	estimado	7531	5890.05	6.3
7	Computador	estimado	4453	3484.41	3.7
8	Máquina de lavar	estimado	4026	3150.91	3.4
9	Ar-condicionado	medido	3958	3065.49	3.3
10	Micro-ondas	estimado	3855	3018.21	3.2
11	Ferro de passar	estimado	1626	1274.96	1.4

Figura 19. q3: participação de cada aparelho no consumo, medido na tomada ou estimado pelo rateio da conta.

O chuveiro responde por 36,8% do consumo (estimado) e a geladeira por 17,7% (medido). O chuveiro é o maior peso, mas a geladeira é o maior consumo medido e o alvo mais claro de manutenção.

q4: algum aparelho está gastando mais do que deveria?

```
-- q4: Quais aparelhos estão gastando mais do que deveriam?
SELECT rotulo, status, count(*) AS aparelhos, round(avg(excesso_pct), 0) AS excesso_medio_pct,
       round(avg(rs_excesso_mes), 2) AS rs_excesso_medio_mes
FROM workspace.gs.mvp_alertas_aparelho
GROUP BY rotulo, status
ORDER BY rotulo, status;
```

Table +

	rotulo	status	aparelhos	excesso_medio_pct	rs_excesso_medio_mes
1	Ar-condicionado	normal	22	null	null
2	Ar-condicionado	sem_base	16	null	null
3	Demais aparelh...	atencao	2	33	44.52
4	Demais aparelh...	critico	3	68	68.57
5	Demais aparelh...	normal	95	null	null
6	Freezer	atencao	3	32	14.16
7	Freezer	critico	2	38	18.8
8	Freezer	normal	25	null	null
9	Geladeira	atencao	8	31	10.28
10	Geladeira	critico	12	41	13.73
11	Geladeira	normal	80	null	null

Figura 20. q4: aparelhos por status de alerta, com excesso médio e custo extra por mês.

Há alertas em 20 geladeiras, 5 freezers e 5 casas com consumo sem explicação nos aparelhos sem sensor. Cada aparelho é comparado com ele mesmo nos 30 primeiros dias de uso, descontando a temperatura. Os 16 aparelhos de ar-condicionado sem 30 dias de uso ficam como `sem_base` e não geram alerta sem fundamento.

q5 (impacto): quanto as famílias economizam?

```
-- q5 (IMPACTO): Quanto as famílias economizam resolvendo os problemas apontados?
WITH alertas AS (
  SELECT residencia_hash, sum(kwh_excesso_mes) AS kwh_mes, sum(rs_excesso_mes) AS rs_mes
  FROM workspace.gs.mvp_alertas_aparelho
  WHERE status IN ('atencao', 'critico')
  GROUP BY residencia_hash
),
ultimo_mes AS (
  SELECT residencia_hash, kwh_total / dias_medidos * 30 AS kwh_30_dias
  FROM workspace.gs.mvp_painel_mensal
  WHERE ano_mes = (SELECT max(ano_mes) FROM workspace.gs.mvp_painel_mensal)
)
SELECT count(*) AS casas_com_alerta,
       round(sum(a.kwh_mes), 1) AS kwh_evitaveis_mes,
       round(sum(a.rs_mes), 2) AS rs_evitaveis_mes,
       round(sum(a.rs_mes) * 12, 2) AS rs_evitaveis_ano,
       round(avg(a.rs_mes), 2) AS economia_media_por_casa_mes,
       round(100 * sum(a.kwh_mes) / sum(u.kwh_30_dias), 1) AS reducao_pct_nessas_casas
FROM alertas a
JOIN ultimo_mes u USING (residencia_hash);
```

Table +

	casas_com_alerta	kwh_evitaveis_mes	rs_evitaveis_mes	rs_evitaveis_ano	economia_media_por_casa_mes	reducao_pct_nessas_casas
1	30	799.4	621.8	7461.6	20.73	10.5

Figura 21. q5: economia possível se os problemas apontados forem resolvidos.

> 30 casas com alerta poderiam deixar de gastar 799,4 kWh e R$ 621,80 por mês (R$ 7.461,60 por ano), em média R$ 20,73 por casa, uma redução de 10,5% no consumo dessas famílias.

q6 (validação): a detecção encontra as falhas injetadas?

```
-- q6 (validação): A detecção encontra as falhas injetadas pelo simulador?
WITH total AS (
  SELECT count_if(resultado = 'verdadeiro_positivo') AS vp,
         count_if(resultado = 'falso_positivo') AS fp,
         count_if(resultado = 'falso_negativo') AS fn,
         count_if(resultado = 'verdadeiro_negativo') AS vn,
         round(avg(dias_ate_detectar), 1) AS dias_medios_ate_detectar
  FROM workspace.gs.ouro_validacao_deteccao
)
SELECT vp, fp, fn, vn,
       round(100 * try_divide(vp, vp + fp), 1) AS precisao_pct,
       round(100 * try_divide(vp, vp + fn), 1) AS cobertura_pct,
       dias_medios_ate_detectar
FROM total;
```

Table +

	vp	fp	fn	vn	precisao_pct	cobertura_pct	dias_medios_ate_detectar
1	31	0	0	221	100	100	9.9

Figura 22. q6: comparação dos alertas com o gabarito do simulador.

Foram 31 falhas detectadas, nenhum alarme falso e nenhuma perdida, em média 9,9 dias após o início. Uma das 32 falhas injetadas não pôde ser avaliada por falta de 30 dias de uso. Esse resultado vale para dados simulados, em que os defeitos são nítidos; em uso real, a taxa tende a ser menor.

09. Conclusão técnica

O pipeline coleta quatro fontes reais e três simuladas no Airflow, envia lotes ao Volume e trata os dados em camadas no Databricks. A Bronze é incremental e não duplica. A Prata tipa, deduplica, aplica dezesseis regras de qualidade com contagem e faz MERGE. A Ouro entrega um modelo dimensional sem contagem dupla, protege dados pessoais com hash e máscara e alimenta a tela do cidadão pelas tabelas `mvp_*`.

Decisões principais: sensores híbridos, porque um sensor geral lendo por hora não separa o consumo por aparelho; detecção explicável, que compara cada aparelho com ele mesmo e sugere verificação em vez de afirmar defeito; e LGPD aplicada na Ouro.

Limitações: sensores, contas e cadastro são simulados; o custo não inclui ICMS, PIS e COFINS; e um aparelho que já começa com defeito parece normal, porque a referência são os primeiros 30 dias de uso.

Repositório: https://github.com/luanmacea/seguwatts-bigdata